UNIVERSIDADE FEDERAL DE SANTA CATARINA
CENTRO TECNOLÓGICO
DEPARTAMENTO DE INFORMÁTICA E ESTATÍSTICA
CIÊNCIAS DA COMPUTAÇÃO

Ewaldo Uhlmann

Reconhecimento de Texto em Imagens de Obras Literárias Antigas em Português

Florianópolis
2026

Ewaldo Uhlmann

Reconhecimento de Texto em Imagens de Obras Literárias Antigas em Português

Trabalho de Conclusão de Curso submetido ao Curso de Graduação em Ciências da Computação do Centro Tecnológico da Universidade Federal de Santa Catarina como requisito parcial para a obtenção do título de Bacharel em Ciências da Computação.
Orientador: Prof. Renato Fileto, Dr.
Coorientador: Prof. Alckmar Luiz dos Santos, Dr.

Florianópolis
2026

Ewaldo Uhlmann

Reconhecimento de Texto em Imagens de Obras Literárias Antigas em Português

Este Trabalho de Conclusão de Curso foi julgado adequado para obtenção do Título de Bacharel em Ciências da Computação e aprovado em sua forma final pelo curso de Graduação em Ciências da Computação.

Florianópolis, 4 de dezembro de 2026.

Coordenação do Curso

Banca Examinadora:

Prof. Renato Fileto, Dr.
Orientador
Universidade Federal de Santa Catarina

AGRADECIMENTOS

[TODO: Agradecer aqui à família, a quem esteve por perto durante o curso e a quem mais fizer sentido.]

Ao Prof. Renato Fileto, pela orientação, pela paciência e pelas revisões que deram forma a este trabalho.

Ao Prof. Alckmar Luiz dos Santos e ao NUPILL, por abrirem o acervo, pela ajuda na escolha das obras e por todo o apoio com as passagens e grafias mais difíceis de ler.

[TODO: Colegas, amigos, banca ou outras pessoas que ajudaram no caminho.]

À Universidade Federal de Santa Catarina e aos professores do curso de Ciências da Computação, pela formação ao longo desses anos.

RESUMO

Este trabalho avalia ferramentas de reconhecimento óptico de caracteres (OCR) aplicadas a imagens de obras literárias impressas em português, dos séculos XVIII a XX, do acervo do NUPILL (Núcleo de Pesquisas em Informática, Literatura e Linguística da UFSC). O objetivo é selecionar a ferramenta mais adequada à digitalização desse acervo. Para avaliar as ferramentas nesse contexto, foi construída uma regra ouro com 20 páginas de cinco obras, transcritas manualmente e classificadas em três níveis de dificuldade. Dez ferramentas foram comparadas: motores clássicos e baseados em redes neurais (Tesseract, EasyOCR, PaddleOCR, DocTR e a camada de texto do ABBYY FineReader presente nos PDFs), modelos de visão-linguagem executados localmente (GLM-OCR, Qwen2.5-VL 7B, Gemma 4 E4B e DeepSeek-OCR) e um serviço via API (LlamaParse). A comparação considerou as taxas de erro por caractere e por palavra (CER e WER), a robustez, a fidelidade às grafias antigas e o custo computacional e financeiro. Os modelos de visão-linguagem obtiveram os menores erros: o Qwen2.5-VL 7B alcançou CER médio de 1,6%, e o GLM-OCR, CER mediano de 0,6%. Parte desses modelos, porém, modernizou grafias antigas (até 26,8% das formas, no Gemma 4), mesmo quando instruída explicitamente a não fazê-lo, ou entrou em laço de repetição em páginas isoladas. Observou-se também que, em parte das ferramentas, a qualidade da digitalização pesou mais no erro do que a idade da tipografia. Selecionou-se o Qwen2.5-VL 7B, que obteve o menor erro médio, sem nenhuma falha, e pode ser executado gratuitamente em GPU na nuvem; o GLM-OCR, mais fiel à ortografia original e executável sem GPU, é indicado como alternativa. Como contribuição complementar, disponibilizam-se um pipeline de extração e um notebook que aplicam o modelo escolhido a livros inteiros.

Palavras-chave: Reconhecimento óptico de caracteres. Obras literárias históricas. Modelos de visão-linguagem. Avaliação comparativa de ferramentas. Digitalização de acervos.

ABSTRACT

This work evaluates Optical Character Recognition (OCR) tools applied to Portuguese literary works printed between the 18th and 20th centuries, from the collection of NUPILL (Núcleo de Pesquisas em Informática, Literatura e Linguística, UFSC), in order to select the most suitable one for digitizing this collection. A ground truth of 20 pages from five works was built, manually transcribed and classified into three difficulty levels. Ten tools were compared: classical and neural-network-based engines (Tesseract, EasyOCR, PaddleOCR, DocTR and the ABBYY FineReader text layer embedded in the PDFs), locally run vision-language models (GLM-OCR, Qwen2.5-VL 7B, Gemma 4 E4B and DeepSeek-OCR) and an API service (LlamaParse). The comparison considered character and word error rates (CER and WER), robustness, fidelity to historical spellings, and computational and financial cost. Vision-language models achieved the lowest error rates: Qwen2.5-VL 7B reached a mean CER of 1.6%, and GLM-OCR a median CER of 0.6%. Some of these models, however, modernized historical spellings (up to 26.8% of the forms, in Gemma 4), even when explicitly instructed not to, or fell into repetition loops on isolated pages. For some of the tools, scan quality also proved more influential on error than the age of the typeface. Qwen2.5-VL 7B was selected, as it achieved the lowest mean error without any failure and can be run for free on a cloud GPU; GLM-OCR, more faithful to the original spelling and able to run without a GPU, is recommended as an alternative. As a complementary contribution, an extraction pipeline and a notebook that apply the selected model to entire books are made available.

Keywords: Optical character recognition. Historical literary works. Vision-language models. Comparative tool evaluation. Document digitization.

LISTA DE FIGURAS

Figura 1 – Diagrama de blocos de um sistema de OCR. 17
Figura 2 – Exemplo de página fácil: *Heloíza*, p. 40. Tipografia serifada, baixa degradação. 33
Figura 3 – Exemplo de página de dificuldade média: *Culto à Mulher* vol. 1, p. 55. Prosa densa, ruído nas bordas. 34
Figura 4 – Exemplo de página difícil: *A Amante Militar*, p. 50. Tipografia séc. XVIII, degradação severa. 35
Figura 5 – Etapas do trabalho. O escopo principal termina na seleção do modelo; o pipeline de extração é uma contribuição complementar. 38
Figura 6 – Tempo de processamento de cada página, por modelo, no equipamento sem GPU. Cada ponto é uma página; o traço vertical marca a mediana. 50
Figura 7 – Tempo médio por página nas digitalizações de cerca de 150 ppi (círculo vazado) e de 300 ppi (círculo cheio), no equipamento sem GPU. 50
Figura 8 – Pico de memória RAM de cada modelo no equipamento sem GPU, considerando todas as páginas. 51
Figura 9 – CER de cada página, por modelo, ordenados pelo CER médio. O formato do marcador indica a classe de dificuldade, e o traço vertical, a mediana do modelo. 53
Figura 10 – CER médio de cada modelo por classe de dificuldade. 54
Figura 11 – CER de cada modelo (linhas) em cada página (colunas), agrupadas por obra. Os valores a partir de 10% estão escritos na célula; a escala de cor satura em 50%. 54
Figura 12 – Proporção das palavras com grafia antiga na regra ouro que cada modelo preservou (barra cheia) e que modernizou (barra hachurada). O restante corresponde a outros erros de reconhecimento. 56
Figura 13 – CER médio de cada modelo em função do tempo mediano por página (esquerda) e do pico de memória RAM no equipamento sem GPU (direita). Marcadores vazados indicam modelos executados em GPU na nuvem, cujo tempo foi medido em outro hardware. 57
Figura 14 – Etapas do pipeline de extração. 66

LISTA DE TABELAS

Tabela 1 – Comparativo das principais técnicas de OCR segundo princípio, vantagens e limitações. 18
Tabela 2 – Ferramentas de OCR consideradas (candidatas e substitutas): categoria, licença, forma de acesso, custo e requisito de GPU. 23
Tabela 3 – Síntese comparativa dos trabalhos relacionados em OCR para documentos históricos. 30
Tabela 4 – Obras selecionadas para composição do corpus de avaliação. 32
Tabela 5 – Páginas selecionadas para a regra ouro, por obra e classe de dificuldade. . . 37
Tabela 6 – Configuração do ambiente computacional local utilizado nos experimentos. 39
Tabela 7 – Modelos excluídos antes dos experimentos, critério de exclusão e substituto. 40
Tabela 8 – Ferramentas avaliadas, categoria e ambiente de execução. 43
Tabela 9 – Execução dos modelos sobre as 20 páginas da amostra, no ambiente da Tabela 6. 49
Tabela 10 – CER e WER (%) de cada modelo sobre as 20 páginas da amostra: médias gerais, CER mediano, número de falhas e CER médio por classe de dificuldade. 52
Tabela 11 – Padrões de erro por modelo: substituições de palavras por tipo e tratamento das grafias anteriores às reformas ortográficas. 55
Tabela 12 – Comparação final entre os dois modelos candidatos. 57
Tabela 13 – Organização do repositório do trabalho. 68

LISTA DE ABREVIATURAS E SIGLAS

API	*Application Programming Interface*
CER	*Character Error Rate* (taxa de erro por caractere)
CNN	*Convolutional Neural Network* (rede neural convolucional)
CPU	*Central Processing Unit*
CRNN	*Convolutional Recurrent Neural Network*
CTC	*Connectionist Temporal Classification*
GPU	*Graphics Processing Unit*
HTR	*Handwritten Text Recognition*
LLM	*Large Language Model* (modelo de linguagem de grande porte)
LSTM	*Long Short-Term Memory*
MoE	*Mixture of Experts* (mistura de especialistas)
NUPILL	Núcleo de Pesquisas em Informática, Literatura e Linguística
OCR	*Optical Character Recognition* (reconhecimento óptico de caracteres)
ppi	*pixels per inch* (pixels por polegada)
RAM	*Random Access Memory*
UFSC	Universidade Federal de Santa Catarina
ViT	*Vision Transformer*
VLM	*Vision-Language Model* (modelo de visão-linguagem)
WER	*Word Error Rate* (taxa de erro por palavra)

SUMÁRIO

1 INTRODUÇÃO 12
1.1 CONTEXTUALIZAÇÃO E JUSTIFICATIVA 12
1.2 OBJETIVOS 13
1.3 OBJETIVOS ESPECÍFICOS 13
1.4 DELIMITAÇÃO DO ESTUDO 13
1.5 CONTRIBUIÇÕES 14
1.6 ORGANIZAÇÃO DO DOCUMENTO 14

2 FUNDAMENTAÇÃO TEÓRICA 16
2.1 RECONHECIMENTO ÓPTICO DE CARACTERES (OCR) 16
2.1.1 Evolução Histórica do OCR 16
2.1.2 O Pipeline de um Sistema OCR 16
2.1.3 Papel do OCR em Projetos de Digitalização de Acervos 16
2.2 PRINCIPAIS TÉCNICAS DE OCR 17
2.2.1 OCR Clássico 18
2.2.2 OCR Baseado em Aprendizado Profundo 18
2.2.3 OCR Baseado em Transformers 19
2.2.4 Modelos de Visão-Linguagem (VLMs) 19
2.3 FERRAMENTAS DE OCR CONSIDERADAS 20
2.3.1 OCR Clássico 20
2.3.2 OCR Baseado em Aprendizado Profundo (CRNN) 20
2.3.3 Baseado em Transformer 21
2.3.4 Modelos de Visão-Linguagem (VLMs) 21
2.3.5 Quadro Comparativo das Ferramentas 22
2.4 MÉTRICAS DE AVALIAÇÃO DE SOLUÇÕES PARA OCR 23
2.4.1 Word Error Rate (WER) 24
2.4.2 Character Error Rate (CER) 24
2.4.3 Complementaridade entre CER e WER 24
2.4.4 Validação Qualitativa e Inspeção Manual 25

3 TRABALHOS RELACIONADOS 26
3.1 PROCESSO DE BUSCA E SELEÇÃO BIBLIOGRÁFICA 26
3.2 OCR PARA DOCUMENTOS HISTÓRICOS E DEGRADADOS 27
3.3 OCR EM PORTUGUÊS 28
3.4 OCR EM DOCUMENTOS HISTÓRICOS EM LÍNGUA PORTUGUESA . 28
3.5 SÍNTESE COMPARATIVA DOS TRABALHOS RELACIONADOS 29

4 CONSTRUÇÃO DA REGRA OURO 31

4.1 ORIGEM DO CORPUS 31
4.2 CRITÉRIOS DE SELEÇÃO DAS OBRAS 31
4.3 CLASSIFICAÇÃO DE DIFICULDADE 32
4.3.1 Páginas Fáceis 32
4.3.2 Páginas de Dificuldade Média 32
4.3.3 Páginas Difíceis 34
4.4 SELEÇÃO DAS PÁGINAS 35
4.5 PROCESSO DE TRANSCRIÇÃO 36
4.6 VALIDAÇÃO DA REGRA OURO 36

5 METODOLOGIA EXPERIMENTAL 38
5.1 AMBIENTE COMPUTACIONAL 38
5.2 MODELOS CANDIDATOS E EXCLUSÕES 39
5.2.1 Requisito de Hardware 40
5.2.2 Disponibilidade 41
5.2.3 Dificuldade de Implementação 41
5.2.4 Custo Financeiro 42
5.2.5 Acesso à API 42
5.2.6 Conjunto Avaliado 42
5.3 CONFIGURAÇÃO DOS MODELOS 42
5.3.1 Tesseract 42
5.3.2 EasyOCR 43
5.3.3 PaddleOCR 43
5.3.4 DocTR 43
5.3.5 VLMs Locais via Ollama 43
5.3.6 LlamaParse 44
5.3.7 Mistral OCR e Gemini 44
5.4 PROTOCOLO DE EXTRAÇÃO 44
5.4.1 Preparação das Páginas 44
5.4.2 Organização do Código 45
5.4.3 Extração e Avaliação em Etapas Separadas 45
5.4.4 Medição de Recursos 45
5.5 PROTOCOLO DE AVALIAÇÃO 46
5.5.1 Normalização do Texto 46
5.5.2 Métricas e Agregação 46
5.5.3 Padrões de Erro 47
5.6 CRITÉRIOS DE SELEÇÃO 47

6 RESULTADOS DOS EXPERIMENTOS 49
6.1 EXECUÇÃO E CUSTO COMPUTACIONAL 49

6.1.1 Equipamento sem GPU 49
6.1.2 GPU na Nuvem 51
6.2 QUALIDADE DO RECONHECIMENTO 51
6.2.1 Desempenho por Obra e Dificuldade 53
6.3 PADRÕES DE ERRO E FIDELIDADE ORTOGRÁFICA 53
6.4 QUALIDADE E CUSTO 55
6.5 SELEÇÃO DO MODELO 56

7 CONCLUSÃO 59
7.1 LIMITAÇÕES 60
7.2 TRABALHOS FUTUROS 61

REFERÊNCIAS 62

APÊNDICE A – PIPELINE DE EXTRAÇÃO 66

APÊNDICE B – PROMPT DOS MODELOS DE VISÃO-LINGUAGEM 67

APÊNDICE C – CÓDIGO-FONTE 68

1 INTRODUÇÃO

Muitas obras literárias em língua portuguesa impressas entre os séculos XVIII e XX estão em estado físico deteriorado, têm acesso restrito ou existem apenas em acervos especializados. A digitalização dessas obras, isto é, a produção de imagens de suas páginas, preserva seu conteúdo e amplia o acesso a elas (1). Uma imagem, porém, não permite buscar palavras, indexar o texto nem analisá-lo por computador. Para isso, é necessária uma segunda etapa: o reconhecimento automático do texto contido nas imagens, tema deste trabalho.

O reconhecimento óptico de caracteres (OCR, do inglês *Optical Character Recognition*) é a tecnologia usada para transformar imagens de documentos em texto editável e processável. O desempenho de sistemas OCR, porém, varia bastante em função das características físicas dos documentos, da qualidade da digitalização e das particularidades linguísticas do texto. Documentos históricos apresentam desafios específicos: degradação do papel, variações tipográficas características da época, entintamento desigual, e, no caso do português, a presença de diacríticos e de vocabulário arcaico. Apesar da disponibilidade de ferramentas de OCR, ainda há pouca sistematização sobre como aplicá-las de forma eficaz em documentos antigos em português, especialmente aqueles que apresentam degradação física, variações tipográficas e ortografia não padronizada (2).

1.1 CONTEXTUALIZAÇÃO E JUSTIFICATIVA

Universidades brasileiras e outras instituições vêm ampliando esforços para digitalizar acervos históricos, para preservar obras antigas e torná-las acessíveis a novas formas de pesquisa (1). O NUPILL[1] (Núcleo de Pesquisas em Informática, Literatura e Linguística) da Universidade Federal de Santa Catarina (UFSC) é um exemplo desse movimento, atuando na interseção entre tecnologia e estudos literários. O núcleo dedica-se ao estudo de acervos literários históricos, combinando abordagens da literatura com métodos computacionais, e, como parte de seus objetivos, busca digitalizar e disponibilizar obras para a pesquisa em Humanidades Digitais. A conversão de documentos para texto digital não se limita à preservação, mas também viabiliza novas formas de uso, como busca textual, indexação e análises em larga escala (3).

As obras do acervo do NUPILL impressas entre os séculos XVIII e XX ilustram bem esses desafios. Esses materiais frequentemente apresentam degradação física, variações tipográficas e ortografia anterior às reformas ortográficas, o que dificulta sua digitalização por métodos tradicionais. Do ponto de vista tecnológico, o OCR avançou muito nos últimos anos. Modelos baseados em arquiteturas de Transformers, como o TrOCR, e, mais recentemente, os modelos de visão-linguagem têm apresentado desempenho superior em diversas tarefas de reconhecimento de texto (4, 5). Ainda assim, pouco se sabe sobre o comportamento desses modelos em textos históricos, sobretudo em línguas com menos recursos que o inglês (6), como

[1] https://nupill.ufsc.br/

o português (2).

Este trabalho trata da digitalização de documentos antigos como os do acervo do NUPILL. Mais do que escolher uma ferramenta para um corpus específico, busca-se compreender e documentar a aplicação de técnicas de OCR a esse tipo de material, de forma que o processo desenvolvido possa ser replicado e adaptado para outras obras literárias.

1.2 OBJETIVOS

O objetivo geral deste trabalho é avaliar ferramentas de reconhecimento óptico de caracteres (OCR) aplicadas a obras literárias antigas em português e selecionar a mais adequada para a digitalização do acervo do NUPILL, considerando a qualidade do reconhecimento, a fidelidade à ortografia original e a viabilidade de uso com os recursos de que núcleos de pesquisa costumam dispor.

1.3 OBJETIVOS ESPECÍFICOS

1. Efetuar uma revisão bibliográfica sobre técnicas e ferramentas de OCR que possam ser aplicadas a textos históricos.
2. Construir um conjunto de referência (regra ouro) por meio da transcrição de uma amostra de páginas representativa do corpus, estratificada por dificuldade.
3. Configurar e executar ferramentas de OCR de diferentes gerações tecnológicas sobre essa amostra, registrando o tempo de processamento e o uso de memória.
4. Comparar as ferramentas segundo métricas de qualidade (CER e WER), robustez, fidelidade às grafias antigas, custo computacional e custo financeiro.
5. Identificar padrões de erro recorrentes, em especial no tratamento de caracteres e grafias históricas.
6. Selecionar a ferramenta mais adequada para o reconhecimento de obras literárias históricas em português no contexto do NUPILL.

Como contribuição complementar, o trabalho disponibiliza um pipeline de extração e um notebook que aplicam a ferramenta selecionada a obras completas (Apêndice A).

1.4 DELIMITAÇÃO DO ESTUDO

Este trabalho concentra-se na avaliação de ferramentas de reconhecimento óptico de caracteres em obras literárias *impressas* em português, com foco em materiais que apresentam degradação física, variações tipográficas e ortografia anterior às reformas ortográficas, típicas de publicações dos séculos XVIII a XX. Manuscritos não fazem parte do escopo.

A pesquisa limita-se à análise de modelos existentes, incluindo abordagens clássicas e baseadas em aprendizado profundo, sem desenvolvimento ou treinamento de novos modelos. A avaliação usa uma amostra de 20 páginas de cinco obras, não a totalidade do acervo do NUPILL, e termina na seleção do modelo. A extração completa do acervo, a avaliação da qualidade em larga escala e o pós-processamento do texto, como a correção linguística automatizada, não fazem parte do escopo e são apontados como trabalhos futuros. O pipeline de extração do Apêndice A é oferecido como ferramenta para essa continuidade.

1.5 CONTRIBUIÇÕES

A principal contribuição deste trabalho é uma avaliação comparativa de dez ferramentas de OCR sobre obras literárias históricas impressas em português, um tipo de material pouco explorado nos estudos anteriores, considerando não apenas a qualidade do reconhecimento, mas também a fidelidade às grafias antigas, a robustez e o custo de execução.

Além disso, o trabalho contribui com uma regra ouro de 20 páginas transcritas e revisadas manualmente; com uma medida da tendência de cada modelo a modernizar grafias antigas, fenômeno apontado pela literatura, mas ainda não quantificado para o português; com o código do benchmark, disponível em repositório público e organizado para que novos modelos possam ser avaliados da mesma forma; e com um pipeline de extração e um notebook que aplicam o modelo escolhido a obras completas, contribuindo para a digitalização de acervos como o do NUPILL.

1.6 ORGANIZAÇÃO DO DOCUMENTO

Este trabalho está estruturado em sete capítulos e três apêndices:

- **Capítulo 1 – Introdução:** apresenta a contextualização do problema, os objetivos, a delimitação do estudo e as contribuições.
- **Capítulo 2 – Fundamentação Teórica:** discute os conceitos de reconhecimento óptico de caracteres, as técnicas e ferramentas consideradas e as métricas de avaliação.
- **Capítulo 3 – Trabalhos Relacionados:** apresenta pesquisas e iniciativas relevantes na área de OCR e digitalização de acervos.
- **Capítulo 4 – Construção da Regra Ouro:** descreve o corpus, a seleção e a classificação das páginas e o processo de transcrição usado como referência.
- **Capítulo 5 – Metodologia Experimental:** descreve o ambiente, os modelos avaliados, os protocolos de extração e de avaliação e os critérios de seleção.
- **Capítulo 6 – Resultados dos Experimentos:** apresenta o custo de execução, a qualidade das transcrições, os padrões de erro e a seleção do modelo.

- **Capítulo 7 – Conclusão:** retoma os principais achados, as limitações do estudo e sugestões para trabalhos futuros.
- **Apêndice A – Pipeline de Extração:** descreve a ferramenta que aplica o modelo selecionado a obras completas.
- **Apêndice B – Prompt dos Modelos de Visão-Linguagem:** reproduz o *prompt* e os parâmetros usados nos VLMs.
- **Apêndice C – Código-Fonte:** indica o repositório com o código do trabalho e descreve sua organização.

2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta os princípios técnicos de OCR, as principais técnicas, as ferramentas consideradas neste trabalho e as métricas de avaliação utilizadas. Os desafios específicos dos documentos históricos e da língua portuguesa são discutidos no Capítulo 3.

2.1 RECONHECIMENTO ÓPTICO DE CARACTERES (OCR)

O Reconhecimento Óptico de Caracteres (OCR) é a tecnologia que transforma imagens de texto em formatos legíveis por máquina, permitindo a conversão de documentos impressos ou manuscritos em texto digital editável e processável (7). As primeiras patentes de dispositivos de leitura óptica de caracteres datam das décadas de 1920 e 1930 (7).

2.1.1 Evolução Histórica do OCR

As primeiras aplicações comerciais, nos anos 1950 e 1960, reconheciam fontes específicas, projetadas para leitura por máquina, em setores como o bancário e o postal. Nas décadas seguintes, os sistemas passaram a reconhecer múltiplas fontes, com base em características geométricas e classificadores estatísticos (7). A partir dos anos 2010, redes neurais profundas substituíram essas características definidas manualmente, e o reconhecimento passou a ser aprendido diretamente a partir das imagens, o que ampliou o uso do OCR em documentos históricos e degradados (8). Mais recentemente, arquiteturas Transformer e modelos de visão-linguagem passaram a tratar o reconhecimento como geração de texto a partir da imagem (4, 5).

2.1.2 O Pipeline de um Sistema OCR

Um sistema de OCR tradicional é organizado como uma sequência de etapas, cada uma operando sobre o resultado da anterior: o pré-processamento melhora a imagem (remoção de ruído, binarização e correção de inclinação); a segmentação a divide em linhas, palavras e caracteres; a extração de características converte cada região em uma representação numérica; e a classificação compara essa representação com padrões conhecidos para decidir qual caractere foi reconhecido. A Figura 1 ilustra essas etapas.

2.1.3 Papel do OCR em Projetos de Digitalização de Acervos

Em projetos de digitalização de acervos, a imagem preserva o documento, mas é o texto produzido pelo OCR que permite buscar, indexar e analisar as obras por computador (1). Como a qualidade desse texto condiciona as análises feitas sobre ele, erros de reconhecimento em coleções históricas afetam diretamente a pesquisa em Humanidades Digitais (6).



Figura 1 – Diagrama de blocos de um sistema de OCR.

Fonte: Adaptado de (9).

2.2 PRINCIPAIS TÉCNICAS DE OCR

A evolução dos sistemas de reconhecimento óptico de caracteres produziu quatro gerações tecnológicas distintas, cada uma com princípios de funcionamento, pontos fortes e limitações próprios. Essas diferenças orientam a escolha de ferramentas para cada tipo de material, como as obras literárias antigas em português. O **OCR Clássico** opera por segmentação de caracteres e correspondência com padrões pré-definidos, sendo leve e reprodutível, mas frágil diante de degradação física. O **OCR baseado em Aprendizado Profundo** combina redes convolucionais (CNN) com redes recorrentes (LSTM) para processar linhas de texto, generalizando melhor do que o clássico, porém ainda dependente de uma segmentação de boa qualidade. Os modelos **Transformer** aplicam mecanismos de atenção sobre patches da imagem, capturando dependências de longo alcance dentro da página, o que ajuda a lidar com variações tipográficas ao longo de uma mesma linha. Por fim, os **Modelos de Visão-Linguagem (VLMs)** dispensam qualquer etapa de segmentação explícita: recebem a imagem completa e geram a transcrição por geração autorregressiva, aproveitando conhecimento linguístico pré-treinado em larga escala, ao custo de uma tendência a modernizar grafias históricas. A Tabela 1 resume essas quatro abordagens segundo seus respectivos princípios de funcionamento, principais vantagens e limitações mais relevantes para o contexto deste trabalho.

Tabela 1 – Comparativo das principais técnicas de OCR segundo princípio, vantagens e limitações.

Técnica	**Princípio**	**Vantagens**	**Limitações**
OCR Clássico	Segmentação de caracteres + correspondência de padrões	Leve, sem GPU, reprodutível	Falha com degradação e fontes incomuns
Aprendizado Profundo (CRNN)	CNN + LSTM sobre linhas segmentadas	Generaliza melhor que o clássico	Depende de segmentação de linhas
Transformer (ViT + decoder)	Atenção global sobre patches da imagem	Captura contexto de longo alcance	Sensível a scripts não vistos no treino
VLM	Geração autorregressiva sobre imagem completa	Sem segmentação; lida com layouts complexos	Normaliza ortografia histórica implicitamente

Fonte: Elaborado pelo autor.

2.2.1 OCR Clássico

Os primeiros sistemas de OCR comercialmente viáveis operavam por meio de correspondência de padrões (*template matching*) e análise de características geométricas dos glifos. Nessa abordagem, cada caractere é segmentado individualmente da imagem e comparado a um conjunto de moldes pré-definidos; o caractere cujo molde apresenta maior similaridade é o reconhecido. Sistemas posteriores passaram a extrair características como proporções, ângulos de traços e número de extremidades, usadas por classificadores estatísticos (7).

A principal limitação dessa abordagem em documentos históricos é a dependência de uma segmentação precisa: quando a degradação física distorce ou une caracteres adjacentes, toda a cadeia de reconhecimento é prejudicada. Além disso, fontes e estilos tipográficos não presentes no conjunto de treinamento resultam em taxas de erro elevadas (8).

2.2.2 OCR Baseado em Aprendizado Profundo

A partir dos anos 2010, redes neurais convolucionais (CNNs) passaram a substituir os classificadores tradicionais no núcleo dos sistemas OCR. Em vez de extrair características manualmente definidas, as CNNs aprendem representações hierárquicas diretamente dos pixels da imagem durante o treinamento, tornando-se capazes de generalizar para variações tipográficas e de qualidade que os métodos clássicos não conseguiam tratar (8).

Uma arquitetura amplamente adotada combina CNNs para extração de características visuais com redes neurais recorrentes do tipo LSTM (*Long Short-Term Memory*) para modelagem sequencial do texto, formando a arquitetura CRNN (*Convolutional Recurrent Neural Network*)

(10, 11). Essa combinação permite que o modelo considere o contexto de caracteres vizinhos ao realizar o reconhecimento, reduzindo ambiguidades. Embora ofereçam desempenho superior ao OCR clássico em documentos com degradação moderada, esses modelos ainda dependem de segmentação de linhas de qualidade e podem falhar em tipografias muito distintas das presentes em seus dados de treinamento (8).

2.2.3 OCR Baseado em Transformers

A arquitetura Transformer, introduzida originalmente para processamento de linguagem natural, foi adaptada para visão computacional com o desenvolvimento do Vision Transformer (ViT), que divide a imagem em *patches* e aplica mecanismos de atenção para capturar dependências globais entre regiões distantes da imagem (12, 13). No contexto de OCR, essa capacidade é particularmente relevante: ao contrário das CNNs, que processam a imagem de forma local e hierárquica, o Transformer pode relacionar diretamente um traço em uma extremidade da linha com o contexto tipográfico em outra.

Modelos baseados nessa arquitetura combinam um encoder visual do tipo ViT com um decoder de linguagem em uma estrutura encoder-decoder de ponta a ponta, pré-treinada em larga escala e refinada para tarefas específicas de reconhecimento. O TrOCR, principal representante dessa abordagem, superou sistemas baseados em CRNN em *benchmarks* de texto impresso e manuscrito (4). Como reconhece uma linha por vez, porém, depende de uma segmentação prévia, e a literatura revisada por Vesalainen et al. (14) aponta sua sensibilidade à qualidade dessa segmentação e a fontes não vistas no treinamento, limitação relevante para obras do século XVIII.

2.2.4 Modelos de Visão-Linguagem (VLMs)

A geração mais recente de sistemas de reconhecimento de texto é composta por modelos de visão-linguagem (*Vision-Language Models*, VLMs), que processam a imagem completa da página, sem etapa explícita de segmentação de linhas ou caracteres, e geram a transcrição como saída de um modelo de linguagem generativo. Esses modelos recebem a imagem diretamente e produzem texto por meio de geração autorregressiva, aproveitando o conhecimento linguístico adquirido no pré-treinamento em grandes volumes de texto e imagens (5).

Em documentos com *layouts* complexos, múltiplas colunas e mistura de fontes, a ausência de uma etapa de segmentação elimina uma fonte recorrente de erros. Em textos ingleses do século XVIII, Vesalainen et al. (14) observaram que um VLM (Qwen2.5-VL 7B) obteve CER e WER menores que o TrOCR e foi mais robusto a imagens degradadas. Os mesmos autores identificaram, porém, uma limitação crítica: a tendência desses modelos a realizar normalização ortográfica implícita, modernizando grafias históricas sem sinalizar a mudança, comportamento problemático para aplicações que exigem fidelidade diplomática ao original.

2.3 FERRAMENTAS DE OCR CONSIDERADAS

Esta seção apresenta as ferramentas de reconhecimento automático de texto consideradas neste trabalho. Parte delas foi excluída ou substituída por outra variante antes dos experimentos (Seção 5.2), e o conjunto efetivamente avaliado está na Tabela 8. As ferramentas consideradas abrangem as quatro gerações tecnológicas descritas na Seção 2.2: OCR clássico, aprendizado profundo (CRNN), Transformers e modelos de visão-linguagem. As avaliadas cobrem três delas, porque o único representante dos Transformers foi excluído antes dos experimentos. Para cada ferramenta são indicados o modelo de acesso, o regime de custo e os requisitos de hardware, aspectos relevantes para a replicabilidade do benchmark.

2.3.1 OCR Clássico

O **Tesseract** (15) é um motor OCR de código aberto, hoje mantido pela comunidade, licenciado sob Apache 2.0. Originalmente desenvolvido pela Hewlett-Packard nos anos 1980, é o único representante desta categoria que opera de forma genuinamente clássica na etapa de segmentação: após extrair regiões de texto, utiliza uma rede LSTM interna apenas para o reconhecimento de linhas já segmentadas, sem detector neural de texto. Opera inteiramente em CPU, sem necessidade de GPU, e suporta mais de 100 idiomas incluindo o português.

2.3.2 OCR Baseado em Aprendizado Profundo (CRNN)

O **EasyOCR** (16) é uma biblioteca Python de código aberto, licenciada sob Apache 2.0, que implementa uma arquitetura de dois estágios: detecção com o algoritmo CRAFT (*Character Region Awareness for Text Detection*) (17), seguida de reconhecimento com uma rede CRNN (10), que combina camadas convolucionais, uma LSTM bidirecional (11) e a função de perda CTC (*Connectionist Temporal Classification*) (18). Suporta mais de 80 idiomas e pode utilizar GPU opcionalmente. Sua interface simplificada a torna acessível sem configuração extensa.

O **PaddleOCR** (19) é desenvolvido pela Baidu e disponibilizado sob licença Apache 2.0. Utiliza uma arquitetura de três estágios: detecção, classificação de orientação e reconhecimento, com modelos baseados em redes convolucionais e recorrentes pré-treinados para múltiplos idiomas. Suporte a GPU é opcional e o modelo para português está disponível na distribuição padrão.

O **DocTR** (*Document Text Recognition*) (20) é uma biblioteca de código aberto da Mindee, licenciada sob Apache 2.0, que implementa pipelines OCR com suporte a backends TensorFlow e PyTorch. Combina detectores baseados em DBNet (21) ou LinkNet (22) com reconhecedores CRNN (10) ou SAR (23), sendo projetada para documentos estruturados, com suporte opcional a GPU.

2.3.3 Baseado em Transformer

O **TrOCR** (4) é um modelo desenvolvido pela Microsoft, disponível gratuitamente no Hugging Face sob licença MIT, que combina um encoder Vision Transformer (ViT) com um decoder de linguagem baseado em Transformer em uma arquitetura *encoder-decoder* pré-treinada em larga escala. Entre as variantes disponíveis estão a `base-handwritten` e a `large-handwritten`, ajustadas para texto manuscrito (4). O uso de GPU é recomendado para tempo de inferência aceitável, especialmente na variante *large*.

2.3.4 Modelos de Visão-Linguagem (VLMs)

Os modelos de visão-linguagem podem ser acessados de duas formas: execução local, por meio do **Ollama** (24), uma plataforma de código aberto que simplifica o download e a execução de modelos em hardware local, ou via API, em que o processamento ocorre em servidores remotos mediante pagamento por volume de páginas ou tokens. Os modelos locais oferecem maior controle sobre os dados e custo zero por inferência, ao custo de exigirem GPU para tempo de resposta aceitável; os modelos via API eliminam essa dependência de hardware, mas implicam custo financeiro e envio das imagens a terceiros.

O **Gemma 4** (25) é desenvolvido pelo Google DeepMind, lançado em abril de 2026 sob licença Apache 2.0. Disponível em quatro tamanhos (E2B, E4B, 26B e 31B) via Ollama, combina compreensão visual e geração de texto sem etapa explícita de segmentação.

O **DeepSeek-VL2** (26), da DeepSeek, é um VLM de uso geral com arquitetura de mistura de especialistas (*Mixture of Experts*, MoE), com variantes de 1,0B, 2,8B e 4,5B de parâmetros ativos. A mesma empresa disponibiliza o **DeepSeek-OCR** (27), voltado especificamente ao reconhecimento de documentos. O DeepSeek-OCR combina um codificador visual de cerca de 380 milhões de parâmetros, que comprime a imagem em poucos *tokens*, com um decodificador MoE de 3 bilhões de parâmetros, dos quais cerca de 570 milhões são ativados por *token*.

O **Qwen2.5-VL** (5) é desenvolvido pelo Qwen Team da Alibaba Cloud, disponível sob licença Apache 2.0 via Ollama. Projetado para compreensão de documentos, emprega um Vision Transformer de resolução dinâmica nativa e se destaca em extração estruturada de formulários, tabelas e *layouts* complexos (5).

O **GLM-OCR** (28), da Z.ai, é um modelo de cerca de 0,9 bilhão de parâmetros especializado em reconhecimento de documentos, que combina um codificador visual de 0,4 bilhão de parâmetros com um decodificador de linguagem de 0,5 bilhão. Por ser pequeno, é um dos poucos VLMs que cabem na memória de um computador pessoal sem GPU (29).

O **LlamaParse** (30) é um serviço da LlamaIndex, acessado via API, que oferece modos de processamento com e sem modelos de linguagem. O custo por página varia conforme o modo: o modo básico (`parse_page_without_llm`) extrai o texto sem modelo de linguagem e é o mais barato, enquanto os modos agênticos (`parse_page_with_agent`), que empregam modelos de

linguagem, custam de 10 a 45 vezes mais (Tabela 2).

O **Mistral OCR** (31) é um serviço da Mistral AI acessado via API e cobrado por página, com suporte a documentos com *layouts* complexos e fórmulas matemáticas.

O **Gemini 2.0 Flash** (32) é um modelo do Google acessado via API, cobrado por *tokens* e com camada gratuita, descontinuado em junho de 2026.

Além dessas ferramentas, uma solução comercial foi incluída como referência: o **ABBYY FineReader** (33), software comercial de OCR amplamente usado em bibliotecas. Os PDFs do acervo já contêm uma camada de texto gerada por ele no momento da digitalização, como descrito na Seção 5.2.

2.3.5 Quadro Comparativo das Ferramentas

A seleção das ferramentas avaliadas neste trabalho foi orientada por dois critérios principais: cobertura das quatro gerações tecnológicas descritas na Seção 2.2 e uso em estudos recentes de OCR aplicado a documentos históricos (4, 14). Foi selecionada ao menos uma ferramenta de cada geração tecnológica, dentre as mais populares e bem avaliadas na literatura e na Web, com um número maior de ferramentas recentes, por serem as mais promissoras para lidar com os desafios do OCR em obras antigas. O **Tesseract** foi incluído por ser a referência canônica de código aberto, amplamente utilizado como *baseline* em estudos comparativos. O **EasyOCR** e o **PaddleOCR** foram escolhidos por oferecerem suporte explícito ao português e instalação simplificada, enquanto o **DocTR** se destaca por integrar detecção e reconhecimento em um único pipeline moderno baseado em aprendizado profundo.

Na categoria Transformer, o **TrOCR** foi considerado em duas variantes (`base` e `large`) por ser a principal referência de OCR baseado em Transformer (4), mas acabou excluído antes dos experimentos por limitações de hardware e de implementação (Seção 5.2). Entre os VLMs locais, o **Gemma 4**, o **DeepSeek-VL2** e o **Qwen2.5-VL** foram selecionados por serem executáveis sem custo via Ollama; o **GLM-OCR** e o **DeepSeek-OCR** entraram depois, como substitutos de candidatos que não puderam ser executados. Por fim, entre os serviços via API, o **LlamaParse** (nos modos básico e agêntico), o **Mistral OCR** e o **Gemini 2.0 Flash** foram incluídos para cobrir o espectro de soluções comerciais com diferentes relações custo-desempenho, permitindo comparação direta com as alternativas locais. Parte dessas ferramentas acabou excluída antes dos experimentos, por limitações de hardware, disponibilidade, custo ou acesso às APIs, como detalhado na Seção 5.2.

A Tabela 2 apresenta uma visão consolidada de todas as ferramentas, indicando para cada uma: a categoria tecnológica, a licença de uso, a forma de acesso (local ou API), o regime de custo e a necessidade de GPU.

Tabela 2 – Ferramentas de OCR consideradas (candidatas e substitutas): categoria, licença, forma de acesso, custo e requisito de GPU.

Ferramenta	**Categoria**	**Licença**	**Acesso**	**Custo**	**GPU**
Tesseract*	OCR Clássico	Apache 2.0	Local	Gratuito	Não
ABBYY FineReader*	OCR Clássico	Proprietária	Local	Pago	Não
EasyOCR*	Deep Learning (CRNN)	Apache 2.0	Local	Gratuito	Opcional
PaddleOCR*	Deep Learning (CRNN)	Apache 2.0	Local	Gratuito	Opcional
DocTR*	Deep Learning (CRNN)	Apache 2.0	Local	Gratuito	Opcional
TrOCR `base`	Transformer	MIT	Local	Gratuito	Recomenda
TrOCR `large`	Transformer	MIT	Local	Gratuito	Recomenda
Gemma 4 (Ollama)*	VLM local	Apache 2.0	Local	Gratuito	Recomenda
DeepSeek-VL2 (Ollama)	VLM local	Aberta[a]	Local	Gratuito	Recomenda
Qwen2.5-VL (Ollama)*	VLM local	Apache 2.0	Local	Gratuito	Recomenda
DeepSeek-OCR (Ollama)*	VLM local	MIT	Local	Gratuito	Recomenda
GLM-OCR (Ollama)*	VLM local	MIT	Local	Gratuito	Opcional
LlamaParse Basic*	OCR via API	Proprietária	API	Pago[b]	Não
LlamaParse Agentic	VLM via API	Proprietária	API	Pago[b]	Não
Mistral OCR	VLM via API	Proprietária	API	Pago[c]	Não
Gemini 2.0 Flash	VLM via API	Proprietária	API	Pago[d]	Não

* Ferramentas efetivamente avaliadas (Tabela 8); as demais foram excluídas antes dos experimentos (Seção 5.2). [a] DeepSeek-VL2: licença DeepSeek Model License (uso comercial permitido com restrições). [b] LlamaParse opera por créditos (10.000 créditos/mês no plano gratuito): modo Basic custa 1 crédito/página (US$ 0,00125/pág.); modo Agentic custa 10 créditos/página (US$ 0,0125/pág.) (30). [c] Mistral OCR: US$ 2,00/1.000 páginas (padrão) ou US$ 1,00/1.000 páginas (Batch API) (31). [d] Gemini 2.0 Flash: US$ 0,10/milhão de tokens de entrada (32); descontinuado em jun./2026.

Fonte: Elaborado pelo autor.

2.4 MÉTRICAS DE AVALIAÇÃO DE SOLUÇÕES PARA OCR

A qualidade do reconhecimento automático de texto é mensurada por meio de métricas que comparam a saída do sistema com um texto de referência produzido manualmente, denominado *regra ouro* (*ground truth*). As métricas mais consolidadas na literatura de OCR são o *Word Error Rate* (WER) e o *Character Error Rate* (CER), que quantificam, respectivamente, os erros no nível da palavra e do caractere (34). Ambas derivam da distância de edição de Levenshtein (35), isto é, do menor número de substituições, deleções e inserções necessárias para transformar a saída do sistema no texto de referência. Esta seção apresenta essas métricas e

sua complementaridade.

2.4.1 Word Error Rate (WER)

O WER avalia o OCR no nível da palavra, medindo a proporção de palavras reconhecidas incorretamente em relação ao total de palavras no texto de referência. A fórmula é:

$$\text{WER} = \frac{S + D + I}{N} \times 100\%$$

onde:

- S = número de substituições (uma palavra foi reconhecida como uma palavra diferente);
- D = número de deleções (uma palavra foi omitida);
- I = número de inserções (uma palavra extra foi adicionada);
- N = número total de palavras na referência.

O WER se originou na avaliação de sistemas de reconhecimento de fala (36) e foi adotado no OCR por medir os erros em unidades com significado, as palavras (34). Um erro em um único caractere que resulte em uma palavra diferente é contado como um erro de palavra inteiro. Como as inserções entram no numerador, o WER pode ultrapassar 100% quando o sistema gera muito texto espúrio, como em laços de repetição.

2.4.2 Character Error Rate (CER)

O CER mede os erros no nível de caracteres individuais, oferecendo uma visão mais granular. A fórmula é idêntica à de WER, mas aplicada a caracteres:

$$\text{CER} = \frac{S + D + I}{N} \times 100\%$$

onde agora N é o número total de caracteres na referência.

O CER é menos sensível à forma como o texto é dividido em palavras, o que o torna mais adequado para comparar sistemas em línguas e textos com fronteiras de palavras pouco claras (37). Em português histórico, em que um diacrítico ou uma letra distinguem formas diferentes e a separação de palavras nem sempre segue a norma atual, o CER é a métrica principal deste trabalho, complementada pelo WER.

2.4.3 Complementaridade entre CER e WER

O CER costuma ser bem menor que o WER, porque um erro em um único caractere conta como um caractere errado no CER, mas invalida a palavra inteira no WER. Quando os

erros estão espalhados por muitas palavras, um CER moderado pode corresponder a um WER alto; quando estão concentrados em poucas palavras, os dois valores ficam próximos. Por isso, convém reportar as duas métricas: o CER mede a precisão no nível fino, e o WER, o impacto dos erros sobre as palavras que um leitor ou um sistema de busca encontraria (34).

2.4.4 Validação Qualitativa e Inspeção Manual

As métricas quantitativas não mostram que tipo de erro o modelo comete. Para isso, usa-se a inspeção visual dos resultados, que permite classificar os erros em duas categorias principais:

- *Erros Sistemáticos*: ocorrem de forma recorrente sob determinadas condições, como a confusão consistente entre caracteres visualmente similares (por exemplo, “l” e “I”) em uma mesma fonte.
- *Erros Isolados*: manifestam-se de maneira esporádica, sendo geralmente atribuídos a ruído ou a características específicas de páginas individuais.

Erros sistemáticos sugerem limitações fundamentais do modelo que poderiam ser corrigidas por meio de retreinamento ou pós-processamento específico, enquanto erros isolados podem ser mais fáceis de tratar mediante limpeza de dados ou ajustes localizados. A inspeção manual também permite entender o contexto dos erros: um caractere pode ser confundido com outro com maior frequência em certos tipos de *layout*, resoluções de digitalização ou estilos tipográficos. Neste trabalho, essa classificação foi feita alinhando as palavras da referência e da saída de cada modelo e agrupando as diferenças por tipo (Seção 5.5); os casos mais frequentes foram conferidos nas próprias saídas e são discutidos na Seção 6.3.

3 TRABALHOS RELACIONADOS

Este capítulo apresenta trabalhos relacionados ao reconhecimento óptico de caracteres em documentos históricos e obras literárias. A Seção 3.1 descreve o processo de busca e seleção bibliográfica adotado. Em seguida, os trabalhos são organizados em três eixos temáticos: a Seção 3.2 discute pesquisas voltadas ao OCR em documentos históricos e degradados de forma geral, abordando técnicas de pré-processamento, arquiteturas de reconhecimento e os principais desafios do domínio. A Seção 3.3 focaliza especificamente o estado da arte em OCR para a língua portuguesa, que ainda conta com poucos recursos e modelos dedicados. Por fim, a Seção 3.4 restringe o escopo à interseção entre OCR e documentos históricos escritos em português, situando o presente trabalho em relação às iniciativas mais próximas do problema aqui tratado.

3.1 PROCESSO DE BUSCA E SELEÇÃO BIBLIOGRÁFICA

A revisão bibliográfica apresentada neste capítulo, assim como parte da fundamentação teórica do Capítulo 2, foi conduzida por meio de buscas exploratórias em fontes acadêmicas. As buscas cobriram conteúdo indexado em bases como Google Scholar, IEEE Xplore e ACM Digital, complementadas pontualmente por documentação técnica oficial de ferramentas (páginas de projeto, repositórios de código e documentação de API) para a obtenção de especificações factuais sobre produtos específicos, sem valor de embasamento teórico.

As buscas foram realizadas tanto em português quanto em inglês, combinando termos relacionados à tecnologia de OCR, ao domínio de aplicação e ao idioma-alvo. Entre as palavras-chave utilizadas estão: “OCR ferramentas comparação”, “OCR documentos históricos português”, “reconhecimento óptico de caracteres avaliação”, “OCR manuscritos históricos português”, “*historical OCR benchmark*”, “*vision-language model OCR historical documents*”, “*Handwritten Text Recognition historical documents*”, “*OCR post-correction Portuguese*”, “*large language model OCR correction*”, “*Character Error Rate*”, “*Word Error Rate*” e “*OCR evaluation*”. Buscas adicionais e mais específicas foram realizadas a partir dos nomes de ferramentas e modelos identificados nas etapas anteriores (por exemplo, “*Tesseract EasyOCR PaddleOCR TrOCR comparison*”), bem como a partir de autores e termos citados por trabalhos já localizados por outros meios.

O período priorizado foi de 2018 a 2026, com ênfase em publicações a partir de 2023, dado o ritmo acelerado de evolução de arquiteturas baseadas em Transformers e em modelos de visão-linguagem aplicados a OCR. Buscas amplas iniciais, voltadas ao mapeamento geral do estado da arte em OCR, foram seguidas de buscas direcionadas a lacunas identificadas (como OCR aplicado especificamente ao português e a documentos históricos), e complementadas por *snowballing* a partir das referências dos trabalhos mais relevantes encontrados, como Vesalainen et al. (14).

Foram excluídos trabalhos sem relação direta com OCR, ou digitalização de texto, bem

como conteúdo puramente promocional ou de caráter comercial sem embasamento metodológico, este último mantido apenas como fonte factual para especificações técnicas de ferramentas (Seção 2.3), e não como referência de embasamento teórico. Esse processo resultou nos seis trabalhos diretamente relacionados discutidos nas seções seguintes deste capítulo, sintetizados na Tabela 3, complementados pelas referências de fundamentação teórica e técnica apresentadas no Capítulo 2.

3.2 OCR PARA DOCUMENTOS HISTÓRICOS E DEGRADADOS

A aplicação de OCR a obras literárias históricas é um subcampo com desafios próprios. Diferentemente de publicações modernas com tipografia padronizada e alta qualidade de impressão, as obras históricas apresentam condições que sistematicamente prejudicam os motores de reconhecimento, seja por degradação do suporte físico, tinta desbotada ou infiltrada no verso da página (*bleed-through*), iluminação desigual nas digitalizações ou por variações tipográficas da época e ortografia não padronizada (8).

O pré-processamento das imagens é a primeira etapa para lidar com essas dificuldades. A binarização (conversão da imagem colorida ou em tons de cinza para preto e branco) é uma etapa importante, pois separa o conteúdo textual de fatores de ruído como manchas, fundos não uniformes e entintamento irregular (8). Abordagens baseadas em aprendizado profundo, como redes convolucionais e arquiteturas do tipo U-Net, têm superado os métodos tradicionais de limiarização nessa tarefa, especialmente em documentos com alto grau de degradação (38). Apesar desses avanços, sistemas OCR frequentemente falham no reconhecimento de padrões de caracteres quando a degradação é severa, e a escassez de dados anotados para treinamento agrava essas dificuldades (8).

Com a introdução de arquiteturas baseadas em Transformers, o reconhecimento de texto avançou de forma considerável. O modelo TrOCR (4), que combina um encoder visual do tipo Vision Transformer (ViT) com um decoder de linguagem, superou os métodos anteriores em *benchmarks* de texto impresso e manuscrito modernos, tornando-se uma referência importante na área. No entanto, avaliações recentes indicam que modelos baseados em Transformers ainda enfrentam limitações relevantes no contexto histórico, pois são sensíveis à qualidade da segmentação de linhas, a fontes e scripts não vistos durante o treinamento, e à degradação específica de materiais antigos (14).

Um aspecto crítico identificado na literatura recente diz respeito ao comportamento dos modelos de linguagem de grande porte (LLMs) quando aplicados à transcrição histórica. Embora modelos de visão-linguagem (VLMs) como o Qwen2.5-VL apresentem menores taxas de CER e WER que o TrOCR em textos impressos do século XVIII, eles tendem a realizar normalização ortográfica implícita, modernizando grafias históricas de forma silenciosa (14). Esse comportamento pode ser problemático para aplicações acadêmicas que requerem fidelidade diplomática ao texto original, como é o caso deste trabalho. Segundo os mesmos autores, o modelo de OCR dedicado preservou a grafia original com mais consistência, mas foi mais

suscetível à propagação de erros em cascata.

3.3 OCR EM PORTUGUÊS

Apesar do português ser uma das línguas com maior número de falantes no mundo, a pesquisa em OCR voltada especificamente a esse idioma é bem menos desenvolvida do que para o inglês ou outras línguas europeias com mais recursos computacionais. Santos et al. (2) afirmam que o OCR em português permanece largamente inexplorado, mesmo considerando a expressiva base de falantes do idioma.

Do ponto de vista técnico, o português apresenta características que aumentam a dificuldade do reconhecimento automático, como o uso extensivo de diacríticos (til, agudo, circunflexo, grave e cedilha), a alta frequência de vogais acentuadas e, no caso de textos anteriores às reformas ortográficas do século XX, a presença de grafias arcaicas e variações não padronizadas que diferem bastante das formas modernas. Erros nesses diacríticos, embora pequenos no nível do caractere, produzem palavras distintas ou inexistentes no nível da palavra, como se observa nos resultados deste trabalho (Seção 6.3).

No contexto da pós-correção de OCR em português, há indícios de que modelos de linguagem de grande porte podem reduzir bastante as taxas de erro residual. Fritzen (39) avaliou a aplicação de LLMs como Gemma 3 para correção pós-OCR no ESTER-Pt, demonstrando que tais modelos conseguem reduzir o CER do estado da arte em português de 5,12 para 1,69, uma melhoria de aproximadamente 67%. O resultado mostra o potencial dos modelos de linguagem para o idioma e também que parte dos erros não é eliminada por métodos puramente baseados em OCR, sem o auxílio de contexto linguístico.

A escassez de modelos OCR treinados especificamente em corpora históricos em português, diferentemente do que existe para o alemão, o inglês ou o latim, representa um desafio direto para iniciativas como a do NUPILL. Na ausência de modelos para o domínio, a avaliação comparativa de abordagens disponíveis, combinada com análise qualitativa dos padrões de erro, é o caminho adotado neste trabalho para identificar a solução mais adequada.

3.4 OCR EM DOCUMENTOS HISTÓRICOS EM LÍNGUA PORTUGUESA

Há poucos trabalhos sobre OCR em documentos históricos escritos em português, mas as contribuições recentes, apresentadas a seguir, permitem situar o presente trabalho.

Rosa et al. (40) conduziram um estudo de caso envolvendo as ferramentas Google Vision, Docsumo e Transkribus aplicadas à transcrição de manuscritos históricos brasileiros dos séculos XVIII e XIX, escritos em língua portuguesa. Os resultados demonstraram que, embora essas ferramentas apresentem desempenho satisfatório em documentos impressos contemporâneos, ainda enfrentam limitações significativas na transcrição de manuscritos históricos. Entre os principais desafios identificados estão a complexidade da caligrafia, a degradação física dos documentos e as variações linguísticas decorrentes da evolução da língua ao longo do tempo. O

estudo conclui que essas ferramentas ainda precisam evoluir para lidar com as especificidades da escrita manual histórica em português.

No âmbito dos manuscritos históricos portugueses, Aguilar e Jolivet (41) apresentaram um experimento de transcrição automática de manuscritos da Inquisição portuguesa do século XVI utilizando duas ferramentas de HTR (*Handwritten Text Recognition*): o Transkribus, desenvolvido pela ReadCoop, e o Lapelinc Transcriptor, desenvolvido pelo Laboratório de Linguística de Corpus da Universidade Estadual do Sudoeste da Bahia. O experimento concentrou-se na modelagem da escrita de um único copista e na comparação das transcrições automáticas com transcrições diplomáticas produzidas manualmente, sob perspectiva paleográfica. Os resultados mostraram que a expertise paleográfica pesa tanto na interpretação dos resultados quanto na melhoria dos modelos HTR, o que exige colaboração entre especialistas em humanidades e desenvolvedores de tecnologia.

Em escala maior, o projeto TraPrInq (42) aplicou o Transkribus à transcrição de aproximadamente 6.000 documentos digitalizados dos processos da Inquisição portuguesa. Ao longo de nove sessões de treinamento realizadas entre junho de 2022 e julho de 2023, o modelo de reconhecimento de texto em português foi progressivamente refinado a ponto de, a partir da quarta sessão, a transcrição manual poder ser gradualmente substituída pela correção das saídas automáticas do motor. O projeto foi apresentado na conferência Humanidades Digitais e Estudos Inquisitoriais em 2023, e o relato do projeto indica que, com volume suficiente de anotação e iteração de treinamento, é possível atingir qualidade prática em documentos históricos em português, mesmo para caligrafia do século XVII.

Nesses trabalhos, o reconhecimento automático de texto em documentos históricos em língua portuguesa aparece quase sempre aplicado a manuscritos. O presente trabalho se diferencia ao tratar de obras literárias *impressas* de diferentes períodos, avaliando ferramentas de OCR modernas, incluindo VLMs, sobre um corpus estratificado por dificuldade.

3.5 SÍNTESE COMPARATIVA DOS TRABALHOS RELACIONADOS

A Tabela 3 sintetiza os trabalhos revisados neste capítulo segundo cinco dimensões: tipo de documento, idioma do corpus, ferramentas avaliadas, métricas reportadas e principal contribuição. A linha final destaca como o presente trabalho se posiciona em relação ao estado da arte.

A tabela mostra duas lacunas que o presente trabalho procura cobrir. Primeiro, os estudos em língua portuguesa concentram-se em manuscritos históricos (40, 41, 42) ou em texto impresso contemporâneo (2, 39), sem avaliar obras literárias *impressas* de períodos anteriores ao século XX. Segundo, nenhum trabalho revisado combina, em um único benchmark para o português histórico, ferramentas de diferentes gerações tecnológicas, de motores clássicos a VLMs, com corpus estratificado por dificuldade, métricas padronizadas de CER e WER e uma medida da modernização de grafias antigas.

Tabela 3 – Síntese comparativa dos trabalhos relacionados em OCR para documentos históricos.

Trabalho	**Tipo**	**Idioma**	**Ferramentas**	**Métricas**	**Contribuição**
Vesalainen et al. (14)	Impresso histórico	Inglês	TrOCR, Qwen2.5-VL	CER, WER	Padrões de erro e normalização ortográfica implícita por VLMs
Santos et al. (2)	Impresso moderno	Português	Conjunto de avaliação ESTER-Pt	CER	Benchmark de OCR para o português
Fritzen (39)	Impresso moderno	Português	Gemma 3 (pós-OCR)	CER	CER reduzido de 5,12 para 1,69 via LLM
Rosa et al. (40)	Manuscrito histórico	Português	Google Vision, Docsumo, Transkribus	Qualitativa	Manuscritos brasileiros sécs. XVIII–XIX
Aguilar e Jolivet (41)	Manuscrito histórico	Português	Transkribus, Lapelinc	CER	HTR inquisitorial; expertise paleográfica
Baudry (42)	Manuscrito histórico	Português	Transkribus	Qualitativa	6.000 docs. inquisitoriais; treino iterativo
Este trabalho	**Impresso histórico**	**Português**	**10 ferramentas (clássico, CRNN, VLM local e via API)**	**CER, WER, fidelidade ortográfica**	**Benchmark com corpus estratificado**

Fonte: Elaborado pelo autor.

4 CONSTRUÇÃO DA REGRA OURO

A avaliação objetiva de sistemas de reconhecimento óptico de caracteres requer a existência de um conjunto de referência, denominado *regra ouro*, composto por transcrições manuais fiéis ao conteúdo das imagens originais. Sem esse referencial, não é possível calcular métricas como WER e CER de forma confiável, pois não há texto correto com o qual comparar as saídas dos modelos. Este capítulo descreve como essa regra ouro foi constituída: a origem do corpus, os critérios de seleção das obras e das páginas, a classificação de dificuldade adotada, o processo de transcrição e o procedimento de validação.

4.1 ORIGEM DO CORPUS

As obras que compõem o corpus deste trabalho pertencem ao acervo digital do Núcleo de Pesquisas em Informática, Literatura e Linguística (NUPILL), da Universidade Federal de Santa Catarina. O NUPILL mantém uma coleção de textos literários históricos digitalizados, com foco em obras da literatura brasileira e portuguesa, e tem como missão a preservação e o estudo do patrimônio literário por meio de ferramentas computacionais.

A seleção das obras foi realizada em colaboração com o Prof. Dr. Alckmar Luiz dos Santos, pesquisador do NUPILL, que indicou volumes representativos do acervo cujas digitalizações apresentam características adequadas para um estudo de benchmark de OCR, cobrindo um espectro variado de condições tipográficas e de degradação física. Os arquivos são PDFs com a imagem digitalizada de cada página e uma camada de texto gerada pelo ABBYY FineReader. As digitalizações não são homogêneas: *A Amante Militar* e *O Feliz Independente* foram digitalizadas a 300 ppi, e *Heloíza* e os dois volumes de *Culto à Mulher*, com um aplicativo de celular, a cerca de 150 ppi.

4.2 CRITÉRIOS DE SELEÇÃO DAS OBRAS

A seleção priorizou obras que, em conjunto, cobrissem diferentes graus de dificuldade para o reconhecimento automático de texto. Três critérios principais orientaram a escolha:

1. **Variação tipográfica**: presença de tipos serifados modernos, itálicos densos e tipografia do século XVIII com caracteres arcaicos, de modo a expor os modelos a diferentes estilos gráficos.

2. **Grau de degradação física**: desde páginas com baixo ruído e bordas limpas até páginas com manchas sobre o corpo do texto, contraste reduzido e bordas deterioradas.

3. **Complexidade ortográfica**: ortografia da virada do século XX, com diacríticos e grafias em desuso, até ortografia pré-moderna com caracteres fundidos e ausência de espaçamento uniforme.

Com base nesses critérios, foram selecionadas cinco obras do acervo NUPILL, descritas na Tabela 4.

Tabela 4 – Obras selecionadas para composição do corpus de avaliação.

Obra	Autor	Ano	Págs.	Tipografia
Heloíza	J. Mariano de Oliveira	c. 1910	144	Séc. XX, serifada
Culto à Mulher (vol. 1)	J. Mariano de Oliveira	c. 1920	254	Séc. XX, itálica
Culto à Mulher (vol. 2)	J. Mariano de Oliveira	1934	219	Séc. XX, monoespaçada
A Amante Militar	Anônimo	c. 1790	110	Séc. XVIII, arcaica
O Feliz Independente	Pe. T. de Melo	c. 1779	1043	Séc. XVIII, arcaica

Fonte: Elaborado pelo autor.

4.3 CLASSIFICAÇÃO DE DIFICULDADE

Para estruturar a avaliação de forma estratificada, as páginas selecionadas foram classificadas em três níveis de dificuldade: fácil, médio e difícil. Essa classificação foi feita a partir da inspeção visual das imagens, antes dos experimentos, e baseia-se em três eixos observáveis diretamente nas imagens digitalizadas: qualidade tipográfica, grau de degradação física e complexidade ortográfica.

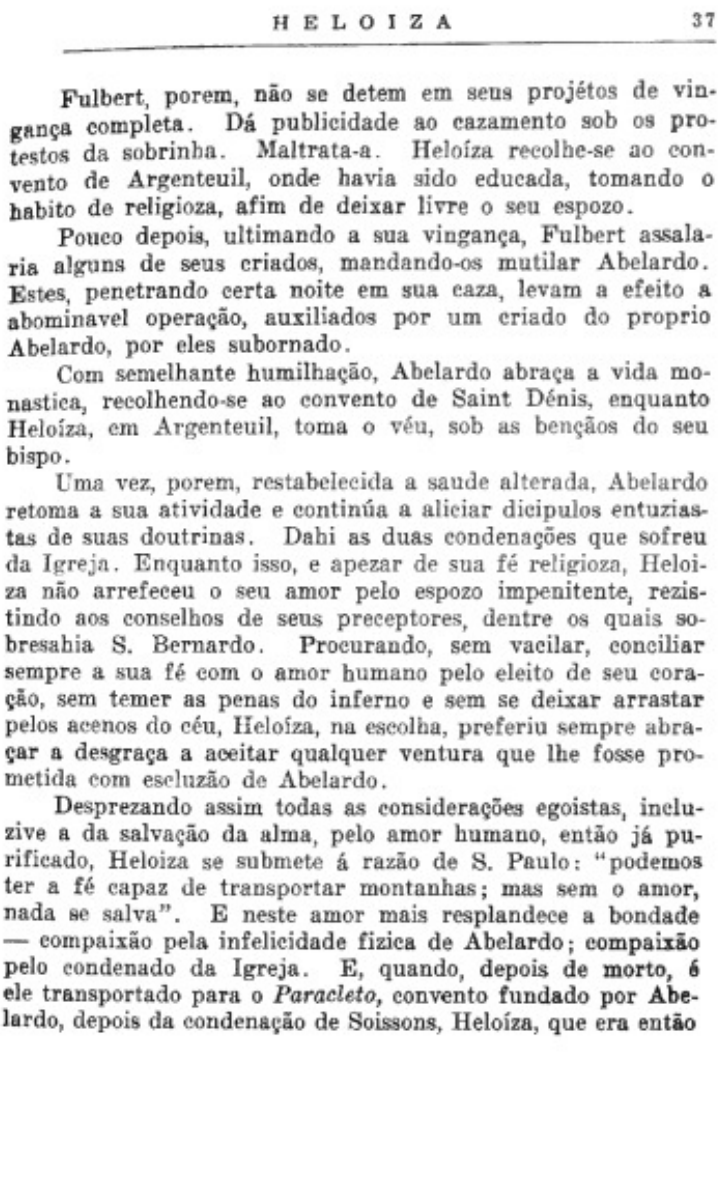
4.3.1 Páginas Fáceis

Páginas classificadas como fáceis apresentam tipografia serifada regular, com espaçamento uniforme entre palavras e linhas, característica de impressões do início do século XX. A degradação física é mínima: eventuais manchas ou ruídos restringem-se às bordas da página, sem afetar o corpo do texto. A ortografia, embora reflita grafias em desuso (como *caza*, *pozitivista* e *si* no lugar de *se*), não apresenta caracteres arcaicos ou ambíguos. Essas condições permitem que modelos OCR convencionais operem próximo ao seu desempenho nominal.

As páginas de *Heloíza* são representativas dessa classe. A Figura 2 ilustra um exemplo típico.

4.3.2 Páginas de Dificuldade Média

Páginas classificadas com dificuldade média caracterizam-se pela presença de múltiplos estilos tipográficos em uma mesma página, combinando trechos em fonte redonda, itálica e negrito de forma intercalada. Além disso, observa-se um nível moderado de degradação física,



HELOIZA 37

Fulbert, porem, não se detem em seus projétos de vingança completa. Dá publicidade ao cazamento sob os protestos da sobrinha. Maltrata-a. Heloíza recolhe-se ao convento de Argenteuil, onde havia sido educada, tomando o habito de religioza, afim de deixar livre o seu espozo.

Pouco depois, ultimando a sua vingança, Fulbert assalaria alguns de seus criados, mandando-os mutilar Abelardo. Estes, penetrando certa noite em sua caza, levam a efeito a abominavel operação, auxiliados por um criado do proprio Abelardo, por eles subornado.

Com semelhante humilhação, Abelardo abraça a vida monastica, recolhendo-se ao convento de Saint Dénis, enquanto Heloíza, em Argenteuil, toma o véu, sob as bençãos do seu bispo.

Uma vez, porem, restabelecida a saude alterada, Abelardo retoma a sua atividade e continúa a aliciar dicipulos entuziastas de suas doutrinas. Dahi as duas condenações que sofreu da Igreja. Enquanto isso, e apezar de sua fé religioza, Heloiza não arrefeceu o seu amor pelo espozo impenitente, rezistindo aos conselhos de seus preceptores, dentre os quais sobresahia S. Bernardo. Procurando, sem vacilar, conciliar sempre a sua fé com o amor humano pelo eleito de seu coração, sem temer as penas do inferno e sem se deixar arrastar pelos acenos do céu, Heloíza, na escolha, preferiu sempre abraçar a desgraça a aceitar qualquer ventura que lhe fosse prometida com esceluzão de Abelardo.

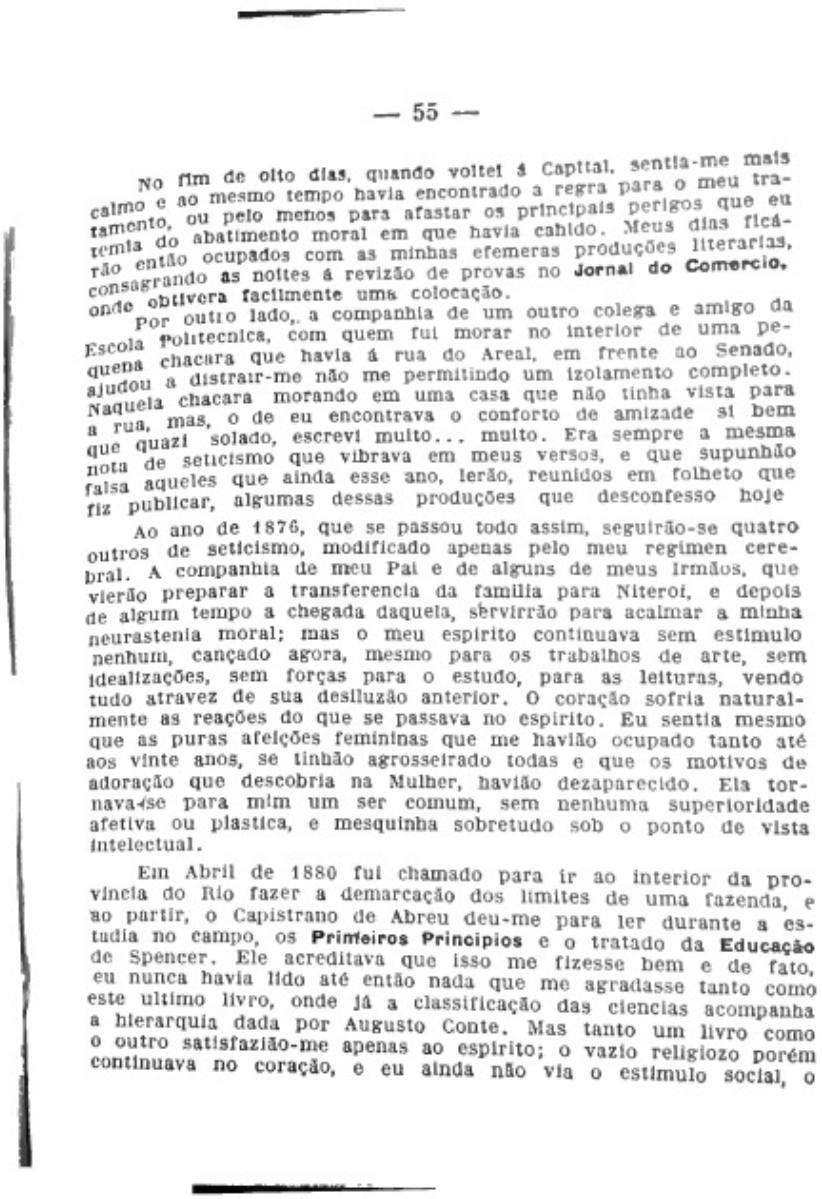
Desprezando assim todas as considerações egoistas, inclusive a da salvação da alma, pelo amor humano, então já purificado, Heloiza se submete á razão de S. Paulo: "podemos ter a fé capaz de transportar montanhas; mas sem o amor, nada se salva". E neste amor mais resplandece a bondade — compaixão pela infelicidade fizica de Abelardo; compaixão pelo condenado da Igreja. E, quando, depois de morto, é ele transportado para o *Paracleto,* convento fundado por Abelardo, depois da condenação de Soissons, Heloíza, que era então

Figura 2 – Exemplo de página fácil: *Heloíza*, p. 40. Tipografia serifada, baixa degradação.

Fonte: NUPILL/UFSC.

que pode comprometer parcialmente a legibilidade do corpo textual. Elementos de layout não convencionais, como poemas com recuos irregulares, notas de rodapé e tabelas de datas, também contribuem para elevar a complexidade do processo de reconhecimento óptico de caracteres. Embora a ortografia apresente características semelhantes às encontradas em páginas de baixa dificuldade, a diversidade tipográfica introduz ambiguidades adicionais, dificultando o desempenho dos modelos de OCR.

Os volumes de *Culto à Mulher* são representativos dessa classe. A Figura 3 ilustra um exemplo.



— 55 —

No fim de oito dias, quando voltei á Capital, sentia-me mais calmo e ao mesmo tempo havia encontrado a regra para o meu tratamento, ou pelo menos para afastar os principais perigos que eu temia do abatimento moral em que havia cahido. Meus dias ficárão então ocupados com as minhas efemeras produções literarias, consagrando as noites á revizão de provas no **Jornal do Comercio**, onde obtivera facilmente uma colocação.

Por outro lado, a companhia de um outro colega e amigo da Escola Politecnica, com quem fui morar no interior de uma pequena chacara que havia á rua do Areal, em frente ao Senado, ajudou a distrair-me não me permitindo um izolamento completo. Naquela chacara morando em uma casa que não tinha vista para a rua, mas, o de eu encontrava o conforto de amizade si bem que quazi solado, escrevi muito... muito. Era sempre a mesma nota de seticismo que vibrava em meus versos, e que supunhão falsa aqueles que ainda esse ano, lerão, reunidos em folheto que fiz publicar, algumas dessas produções que desconfesso hoje

Ao ano de 1876, que se passou todo assim, seguirão-se quatro outros de seticismo, modificado apenas pelo meu regimen cerebral. A companhia de meu Pai e de alguns de meus irmãos, que vierão preparar a transferencia da familia para Niteroi, e depois de algum tempo a chegada daquela, servirrão para acalmar a minha neurastenia moral; mas o meu espirito continuava sem estimulo nenhum, cançado agora, mesmo para os trabalhos de arte, sem idealizações, sem forças para o estudo, para as leituras, vendo tudo atravez de sua desiluzão anterior. O coração sofria naturalmente as reações do que se passava no espirito. Eu sentia mesmo que as puras afeições femininas que me havião ocupado tanto até aos vinte anos, se tinhão agrosseirado todas e que os motivos de adoração que descobria na Mulher, havião dezaparecido. Ela tornava-se para mim um ser comum, sem nenhuma superioridade afetiva ou plastica, e mesquinha sobretudo sob o ponto de vista intelectual.

Em Abril de 1880 fui chamado para ir ao interior da provincia do Rio fazer a demarcação dos limites de uma fazenda, e ao partir, o Capistrano de Abreu deu-me para ler durante a estadia no campo, os **Primeiros Principios** e o tratado da **Educação** de Spencer. Ele acreditava que isso me fizesse bem e de fato, eu nunca havia lido até então nada que me agradasse tanto como este ultimo livro, onde já a classificação das ciencias acompanha a hierarquia dada por Augusto Conte. Mas tanto um livro como o outro satisfazião-me apenas ao espirito; o vazio religiozo porém continuava no coração, e eu ainda não via o estimulo social, o

Figura 3 – Exemplo de página de dificuldade média: *Culto à Mulher* vol. 1, p. 55. Prosa densa, ruído nas bordas.

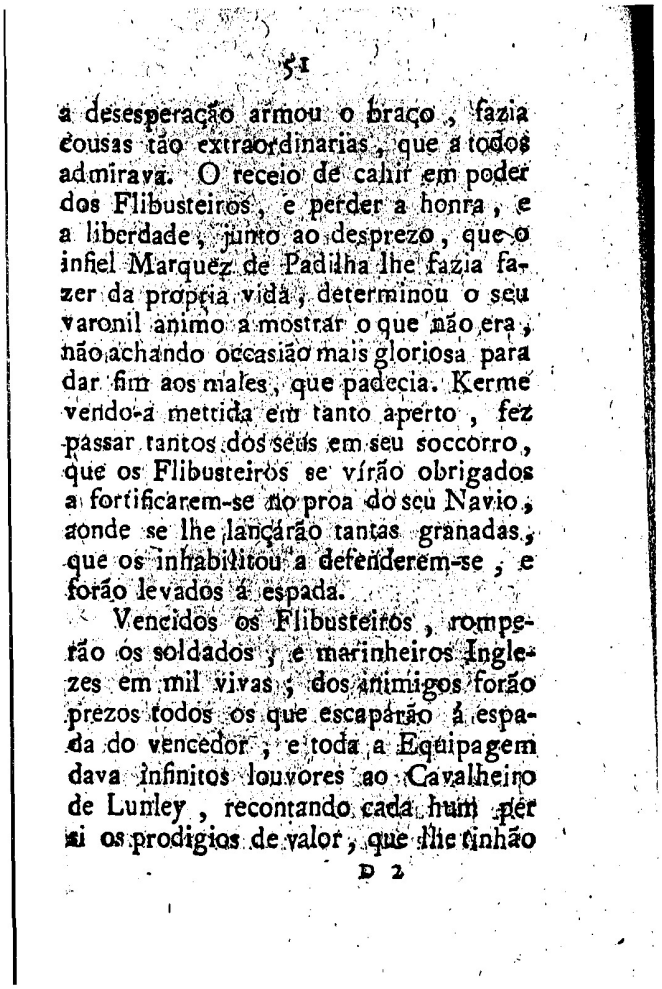
Fonte: NUPILL/UFSC.

4.3.3 Páginas Difíceis

Páginas classificadas como difíceis apresentam uma combinação de fatores que tornam o reconhecimento óptico de caracteres bem mais difícil. O principal deles é a tipografia compacta típica do século XVIII, marcada pela fusão de caracteres, ausência de espaçamento padronizado e pouca distinção visual entre determinados glifos. Soma-se a isso o elevado nível de degradação física dos documentos, incluindo manchas sobre o corpo do texto, bordas escurecidas e redução do contraste, fatores que comprometem diretamente a legibilidade. Além dos desafios visuais, a presença de ortografia pré-moderna, com grafias como *hum*, *aquella* e o uso do *s* longo, impõe dificuldades adicionais aos modelos de OCR, geralmente treinados com base em textos

contemporâneos e padrões ortográficos modernos.

As páginas de *A Amante Militar* são representativas dessa classe. A Figura 4 ilustra um exemplo.



51

a desesperação armou o braço, fazia cousas tão extraordinarias, que a todos admirava. O receio de cahir em poder dos Flibusteiros, e perder a honra, e a liberdade, junto ao desprezo, que o infiel Marquez de Padilha lhe fazia fazer da propria vida, determinou o seu varonil animo a mostrar o que não era, não achando occasião mais gloriosa para dar fim aos males, que padecia. Kerme vendo-a mettida em tanto aperto, fez passar tantos dos seus em seu soccorro, que os Flibusteiros se vírão obrigados a fortificarem-se na proa do seu Navio, aonde se lhe lançárão tantas granadas, que os inhabilitou a defenderem-se, e forão levados á espada.

Vencidos os Flibusteiros, rompe-rão os soldados, e marinheiros Inglezes em mil vivas; dos inimigos forão prezos todos os que escapárão á espada do vencedor, e toda a Equipagem dava infinitos louvores ao Cavalheiro de Lunley, recontando cada hum per si os prodigios de valor, que lhe tinhão

D 2

Figura 4 – Exemplo de página difícil: *A Amante Militar*, p. 50. Tipografia séc. XVIII, degradação severa.

Fonte: NUPILL/UFSC.

4.4 SELEÇÃO DAS PÁGINAS

Foram selecionadas 20 páginas distribuídas entre as cinco obras, de forma alternada ao longo de cada volume, de modo a cobrir diferentes seções do texto e evitar viés de concentração em uma única região do livro. Páginas em branco, páginas de título, frontispícios e páginas com ilustrações sem texto foram excluídas da seleção. A distribuição resultou em 5 páginas fáceis, 8 médias e 7 difíceis, com peso maior nas classes de maior desafio, que são as mais relevantes para a avaliação dos modelos. A Tabela 5 apresenta as páginas selecionadas. A classificação reflete a

percepção visual das páginas antes dos experimentos; a Seção 6.2.1 mostra que, na prática, a qualidade da digitalização pesou mais no erro do que a tipografia.

4.5 PROCESSO DE TRANSCRIÇÃO

As 20 páginas foram transcritas manualmente pelo autor, a partir da leitura direta das imagens ampliadas e sem acesso às saídas dos modelos avaliados. A transcrição seguiu os critérios abaixo:

- **Fidelidade ortográfica**: grafias antigas, acentuação da época, uso de maiúsculas e erros tipográficos do original foram mantidos (*cazamento*, *hum*, *querito*). Nenhuma normalização ortográfica foi aplicada.
- ***S* longo**: o *s* longo das obras do século XVIII foi transcrito como *s*. Trata-se de uma variante tipográfica da mesma letra, e não de uma grafia distinta.
- **Preservação do layout**: cada linha impressa corresponde a uma linha do arquivo, com a hifenização de fim de linha mantida; os recuos de versos e rubricas foram registrados com tabulação, e estrofes e blocos de texto, separados por linha em branco.
- **Elementos incluídos**: títulos, rubricas de personagens, datas e locais ao pé dos poemas, notas de rodapé e suas chamadas, numeração de parágrafos, reclamos e assinaturas de caderno, por serem texto impresso na mancha da página.
- **Elementos excluídos**: numeração de página, cabeçalhos correntes e ornamentos tipográficos.
- **Tratamento de ambiguidades**: leituras incertas foram conferidas em ampliações da imagem, prevalecendo sempre a forma impressa.

4.6 VALIDAÇÃO DA REGRA OURO

Depois de transcritas, as páginas foram conferidas pelo autor contra a imagem original, página por página e linha por linha. Essa revisão contou com o auxílio do NUPILL, coordenado pelo coorientador, Prof. Dr. Alckmar Luiz dos Santos, especialista em literatura brasileira histórica, sobretudo nas passagens de leitura incerta e nas formas ortográficas da época, para que grafias antigas legítimas não fossem confundidas com erros de transcrição.

O resultado é um conjunto de 20 arquivos de texto plano, um por página, que constitui a regra ouro utilizada para o cálculo de CER e WER em todos os experimentos deste trabalho.

Tabela 5 – Páginas selecionadas para a regra ouro, por obra e classe de dificuldade.

Obra	**Pág. PDF**	**Dificuldade**	**Características**
Heloíza	25	Fácil	Prosa + poesia, boa qualidade
Heloíza	40	Fácil	Prosa densa, tipografia clara
Heloíza	70	Fácil	Poesia com múltiplos interlocutores
Heloíza	100	Fácil	Poesia com falas e nota de rodapé
Heloíza	130	Fácil	Prosa densa, nota de rodapé em itálico
Culto à Mulher v. 1	35	Médio	Prosa + orações, layout variado
Culto à Mulher v. 1	80	Médio	Poesia esparsa, degradação lateral
Culto à Mulher v. 1	155	Médio	Poesia + data/local no rodapé
Culto à Mulher v. 1	230	Médio	Prosa muito densa, bordas deterioradas
Culto à Mulher v. 2	20	Médio	Poesia densa, tipografia monoespaçada
Culto à Mulher v. 2	50	Médio	Poesia, degradação moderada
Culto à Mulher v. 2	100	Médio	Prosa curta, mancha sobre o texto
Culto à Mulher v. 2	170	Médio	Prosa densa com título de seção
A Amante Militar	8	Difícil	Texto denso, tipografia séc. XVIII
A Amante Militar	35	Difícil	Caracteres fundidos, ruído moderado
A Amante Militar	65	Difícil	Texto contínuo, degradação média
A Amante Militar	95	Difícil	Prosa densa, alta compactação
O Feliz Independente	50	Difícil	Tipografia séc. XVIII, texto narrativo
O Feliz Independente	200	Difícil	Prosa densa, itálico intercalado
O Feliz Independente	800	Difícil	Texto compacto, degradação nas bordas

Fonte: Elaborado pelo autor.

5 METODOLOGIA EXPERIMENTAL

Este capítulo descreve como os modelos foram configurados, executados, avaliados e comparados. O trabalho segue cinco etapas, ilustradas na Figura 5: a construção da regra ouro, descrita no Capítulo 4; a configuração dos modelos candidatos e a triagem dos que podiam ser executados (Seções 5.1 a 5.3); a extração do texto das páginas da amostra (Seção 5.4); a avaliação das transcrições (Seção 5.5); e a seleção do modelo segundo os critérios da Seção 5.6. Os resultados de cada etapa são apresentados no Capítulo 6. A aplicação do modelo escolhido a obras completas, por meio de um pipeline de extração, é uma contribuição complementar e está descrita no Apêndice A.

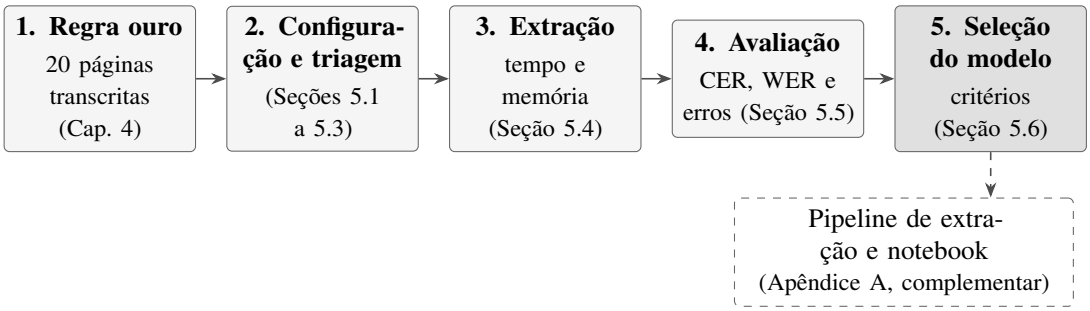


Figura 5 – Etapas do trabalho. O escopo principal termina na seleção do modelo; o pipeline de extração é uma contribuição complementar.

Fonte: Elaborado pelo autor.

As ferramentas candidatas foram escolhidas de modo a cobrir as quatro gerações tecnológicas descritas na Seção 2.2: OCR clássico, modelos baseados em aprendizado profundo, arquiteturas Transformer e modelos de visão-linguagem (VLMs). Como o TrOCR, único representante dos Transformers, foi excluído antes dos experimentos (Seção 5.2), as ferramentas avaliadas cobrem três dessas gerações. A Seção 2.3 descreve cada ferramenta e os critérios dessa escolha. O objetivo é observar como cada geração se comporta em obras literárias históricas em língua portuguesa, material pouco explorado nos estudos anteriores (Seção 3.5).

5.1 AMBIENTE COMPUTACIONAL

Os experimentos locais foram executados em um computador pessoal de uso comum, sem acelerador gráfico dedicado. A escolha foi intencional, já que um dos objetivos do trabalho é indicar uma solução que possa ser adotada por núcleos de pesquisa como o NUPILL, que nem sempre dispõem de infraestrutura de alto desempenho. A Tabela 6 resume a configuração utilizada.

Como o equipamento não possui GPU compatível com CUDA, toda a inferência local foi realizada em CPU. Essa restrição tem duas consequências diretas. A primeira é o tempo de processamento: modelos baseados em redes neurais profundas, em especial os VLMs, levam bem

Tabela 6 – Configuração do ambiente computacional local utilizado nos experimentos.

Componente	**Especificação**
Equipamento	Notebook HP 250 G8
Processador	Intel Core i3-1115G4 (11ª geração), 2 núcleos / 4 *threads*, até 4,1 GHz
Memória RAM	7,5 GiB utilizáveis, com 2 GiB de *swap*
GPU	Intel UHD Graphics integrada, sem suporte a CUDA
Armazenamento	SSD NVMe de 256 GB
Sistema operacional	Ubuntu 22.04.5 LTS (kernel Linux 6.8)
Python	3.10.12
Principais bibliotecas	PyTorch 2.11, Transformers 5.3, PaddlePaddle 2.6.2 (CPU), EasyOCR 1.7.2, DocTR 1.0.1, pytesseract 0.3.13
Motor Tesseract	4.1.1, com dados de idioma `por` e `eng`
Ollama	0.32.15

Fonte: Elaborado pelo autor.

mais tempo por página do que levariam em GPU. A segunda é a memória: VLMs executados via Ollama precisam carregar integralmente os pesos do modelo na RAM, o que restringe o tamanho das variantes que podem ser utilizadas. Em testes preliminares, a variante de 7 bilhões de parâmetros do Qwen2.5-VL (aproximadamente 6 GB) excedeu a memória disponível durante o processamento de uma imagem, levando o sistema operacional a encerrar o processo.

Para não excluir da comparação os VLMs que não cabem nesse equipamento, eles foram executados em um segundo ambiente: o Google Colab (43), na camada gratuita, com uma GPU NVIDIA T4 de 15 GB de memória. O código, o *prompt* e os parâmetros dos modelos foram os mesmos do ambiente local, com o Ollama instalado na própria máquina virtual pelo instalador oficial, na versão disponível na data da execução (2 de outubro de 2026). Essa opção não tem custo financeiro e as imagens são processadas em uma máquina virtual vinculada à conta do próprio usuário, sem passar por um serviço de OCR de terceiros. Os tempos medidos na nuvem, porém, não são comparáveis aos do equipamento local e são reportados em separado (Seção 6.1). O LlamaParse, acessado via API, não depende de nenhum dos dois ambientes, pois o processamento ocorre na infraestrutura do provedor.

5.2 MODELOS CANDIDATOS E EXCLUSÕES

Antes da execução do benchmark, cada modelo candidato foi instalado, configurado e testado. Esses testes mostraram que parte dos modelos selecionados a partir da literatura não poderia ser avaliada nas condições deste trabalho. Os modelos foram excluídos segundo cinco critérios:

1. **Requisito de hardware**: o modelo depende de GPU ou exige mais memória do que o ambiente disponível;
2. **Disponibilidade**: o modelo não está disponível na plataforma de execução adotada para os VLMs locais (Ollama);
3. **Dificuldade de implementação**: o modelo não produziu transcrições utilizáveis sem ajustes que fogem ao escopo do trabalho;
4. **Custo financeiro**: o custo por página é incompatível com uma solução sem custos recorrentes;
5. **Acesso à API**: os limites de uso da conta disponível ou a descontinuação do modelo impediram o processamento das páginas de teste.

A Tabela 7 resume os modelos excluídos, o critério correspondente e, quando houve, o modelo que o substituiu.

Tabela 7 – Modelos excluídos antes dos experimentos, critério de exclusão e substituto.

Modelo	**Critério**	**Motivo**	**Substituto**
TrOCR	Hardware e implementação	Inferência linha a linha inviável em CPU; detector de linhas incompatível com o PyTorch atual; na nuvem, o tokenizador não carregou	–
Gemma 4 E2B	Hardware	Menor variante no Ollama (7,2 GB) excede a memória local	Gemma 4 E4B (GPU)
DeepSeek-VL2	Disponibilidade	Ausente do repositório do Ollama	DeepSeek-OCR (GPU)
Qwen2.5-VL 3B	Hardware	Encerrado por falta de memória em CPU nas páginas de 300 ppi	Qwen2.5-VL 7B (GPU)
Qwen3-VL 2B	Implementação	Devolveu transcrição vazia após esgotar a janela de contexto	GLM-OCR
LlamaParse *Agentic*	Custo	Dez vezes o custo do modo básico	–
Gemini	Acesso à API	Versão 2.0 Flash descontinuada; cota gratuita da versão atual esgotada na primeira página	–
Mistral OCR	Acesso à API	Limite de requisições atingido já na primeira chamada	–

Fonte: Elaborado pelo autor.

5.2.1 Requisito de Hardware

As duas variantes do TrOCR (`base-handwritten` e `large-handwritten`) foram excluídas sem terem sido executadas sobre o corpus. Diferentemente dos VLMs, que recebem a

página inteira em uma única requisição, o TrOCR reconhece apenas uma linha de texto por vez. Cada página precisa, portanto, ser antes segmentada em linhas por um detector de texto externo (neste trabalho, o CRAFT, via `craft-text-detector`), e cada linha resultante passa por uma inferência completa do modelo *encoder-decoder*, com geração autorregressiva do texto (4). Como as páginas do corpus têm tipicamente dezenas de linhas, o custo por página é multiplicado pelo número de linhas. Com 334 milhões de parâmetros na variante `base` e 558 milhões na `large` (4), esse processamento é viável em GPU, mas proibitivo em uma CPU de dois núcleos. Somou-se a isso um obstáculo de manutenção: a biblioteca `craft-text-detector` não é mais mantida e mostrou-se incompatível com as versões atuais do `torchvision`. Na tentativa de execução em GPU na nuvem, o TrOCR também não carregou, porque o tokenizador do modelo não pôde ser instanciado com as versões de bibliotecas daquele ambiente. Contornar esses problemas exigiria fixar versões antigas das bibliotecas, e o modelo foi excluído.

O Gemma 4 foi excluído do ambiente local por memória. A menor variante disponível no Ollama (`gemma4:e2b`) ocupa 7,2 GB (44), praticamente toda a memória do equipamento (7,5 GB), antes mesmo de considerar o sistema operacional e a memória necessária para processar a imagem. Ele foi avaliado na nuvem, na variante E4B.

O Qwen2.5-VL foi inicialmente configurado na variante de 3 bilhões de parâmetros, a única que cabia no equipamento local. Ela processou 12 das 20 páginas da amostra, mas, na página 50 de *O Feliz Independente*, a maior da amostra, o servidor do Ollama foi encerrado pelo sistema operacional por falta de memória, como registrado no *log* do *kernel*. Como a variante não concluiu a amostra no equipamento local, foi substituída pela de 7 bilhões de parâmetros, executada na nuvem, que é também a avaliada por Vesalainen et al. (14).

5.2.2 Disponibilidade

O DeepSeek-VL2 não consta no repositório oficial do Ollama, plataforma adotada para todos os VLMs locais deste trabalho. Executá-lo exigiria outra forma de instalação e inferência, o que quebraria a padronização entre os VLMs locais. Em seu lugar, foi avaliado o modelo da mesma família disponível no Ollama, o DeepSeek-OCR, com 3,3 bilhões de parâmetros e 6,7 GB (45). Como esse tamanho excede a memória livre do equipamento local, ele foi executado na nuvem.

5.2.3 Dificuldade de Implementação

Como alternativas locais de menor porte, foram testados dois modelos disponíveis no Ollama: o Qwen3-VL, na variante de 2 bilhões de parâmetros (1,9 GB), e o GLM-OCR, modelo de 0,9 bilhão de parâmetros especializado em OCR de documentos (1,6 GB) (29). O Qwen3-VL consumiu toda a janela de contexto sem produzir texto na página de teste, comportamento compatível com a geração de raciocínio interno antes da resposta. Contorná-lo exigiria ajustes

específicos desse modelo, e ele foi excluído. O GLM-OCR transcreveu corretamente as páginas de teste e foi incorporado ao conjunto avaliado.

5.2.4 Custo Financeiro

O modo *Agentic* do LlamaParse custa US$ 0,0125 por página, dez vezes o valor do modo básico (30). Por esse motivo, apenas o modo básico foi mantido.

5.2.5 Acesso à API

O Gemini 2.0 Flash, previsto originalmente, foi descontinuado pelo Google em junho de 2026 (32), e a versão 2.5 Flash não está disponível para contas novas. A versão disponível para a conta utilizada, o Gemini 3.8 Flash, chegou a transcrever uma página de teste, mas a cota gratuita se esgotou em seguida. O Mistral OCR recusou as requisições por limite de uso já na primeira chamada. Nos dois casos, a avaliação dependeria de contratar planos pagos, o que contraria o objetivo de uma solução sem custos recorrentes.

5.2.6 Conjunto Avaliado

Após as exclusões e substituições, o conjunto avaliado ficou com dez ferramentas, listadas na Tabela 8. Além dos modelos descritos acima, foi incluído como referência o ABBYY FineReader (33), software comercial de OCR. Os PDFs do acervo já contêm uma camada de texto gerada por ele (versões 11 e 12) no momento da digitalização. Esse texto foi extraído das mesmas páginas e incluído na comparação como referência de uma ferramenta comercial consolidada, sem custo adicional.

Ao longo dos resultados, as ferramentas são agrupadas em três categorias: **Clássico** (motores clássicos e baseados em CRNN, incluindo o ABBYY), **VLM local** (modelos de visão-linguagem executados via Ollama, no equipamento local ou na nuvem) e **Serviço via API** (LlamaParse). O LlamaParse fica nesta última categoria pela forma de acesso: no modo básico, ele processa a página sem um modelo de linguagem.

5.3 CONFIGURAÇÃO DOS MODELOS

5.3.1 Tesseract

O Tesseract foi instalado via gerenciador de pacotes do sistema operacional (`apt install tesseract-ocr tesseract-ocr-por`), incluindo o pacote de dados de idioma para o português (`por`). A invocação foi realizada por meio da biblioteca Python `pytesseract`, com configuração de página `-psm 6` (bloco de texto uniforme) e idioma `por+eng` para lidar com eventuais termos estrangeiros presentes nas obras.

Tabela 8 – Ferramentas avaliadas, categoria e ambiente de execução.

Ferramenta	Categoria	Execução	Versão / variante
ABBYY FineReader	Clássico (comercial)	Camada de texto dos PDFs	11 e 12
Tesseract	Clássico	CPU, equipamento local	4.1.1 (`por+eng`)
EasyOCR	Clássico (CRNN)	CPU, equipamento local	1.7.2
PaddleOCR	Clássico (CRNN)	CPU, equipamento local	2.9.1 (`latin`)
DocTR	Clássico (CRNN)	CPU, equipamento local	1.0.1
GLM-OCR	VLM local	CPU, equipamento local (Ollama)	`glm-ocr:q8_0`
Qwen2.5-VL 7B	VLM local	GPU T4, nuvem (Ollama)	`qwen2.5vl:7b`
Gemma 4 E4B	VLM local	GPU T4, nuvem (Ollama)	`gemma4:e4b`
DeepSeek-OCR	VLM local	GPU T4, nuvem (Ollama)	`deepseek-ocr:3b`
LlamaParse	Serviço via API	Servidores do provedor	modo básico

Fonte: Elaborado pelo autor.

5.3.2 EasyOCR

O EasyOCR foi instalado via `pip install easyocr` sem dependências adicionais além do PyTorch. A inicialização do leitor foi realizada com os idiomas `['pt', 'en']`. Na ausência de GPU compatível com CUDA, a biblioteca executa automaticamente em CPU.

5.3.3 PaddleOCR

A instalação do PaddleOCR exigiu a instalação prévia do framework PaddlePaddle, na versão para CPU. O pacote do PaddleOCR instala variantes da biblioteca OpenCV que entram em conflito com a já utilizada pelo EasyOCR e pelo DocTR, o que exigiu reinstalar manualmente uma única variante. O modelo foi configurado com `lang='latin'`, opção mais próxima disponível para o português no modelo de reconhecimento padrão.

5.3.4 DocTR

O DocTR foi instalado via `pip install python-doctr[torch]`, com o backend PyTorch, e instanciado com os modelos padrão de detecção (`db_resnet50`) e reconhecimento (`crnn_vgg16_bn`), aplicados diretamente sobre as imagens sem configuração adicional.

5.3.5 VLMs Locais via Ollama

O GLM-OCR, o Qwen2.5-VL 7B, o Gemma 4 E4B e o DeepSeek-OCR foram executados por meio da plataforma Ollama, obtidos com o comando `ollama pull` nas variantes da

Tabela 8. A interação foi feita pela API REST local do Ollama, enviando a imagem junto a um *prompt* instrucional padronizado, idêntico para todos os VLMs e reproduzido no Apêndice B, que solicita a transcrição fiel do conteúdo da página, a preservação da ortografia, da acentuação e da pontuação originais, mesmo que arcaicas, e a exclusão de elementos não textuais como numeração de página e ornamentos. Dois modelos são exceção, por terem sido treinados com instruções de tarefa fixas: o GLM-OCR recebe a instrução *Text Recognition:* e o DeepSeek-OCR, a instrução *Free OCR.*, previstas pelos respectivos modelos.

Dois parâmetros do Ollama precisaram ser ajustados para a execução em CPU e foram mantidos na nuvem, para que a configuração fosse a mesma nos dois ambientes. A janela de contexto padrão sem GPU, de 4.096 *tokens*, é insuficiente para uma página inteira, cuja imagem pode gerar mais de 4.000 *tokens*; ela foi ampliada para 6.144. Além disso, o tamanho de lote de processamento do *prompt* (`num_batch`) foi reduzido de 512 para 128, o que diminui o pico de memória sem alterar o modelo nem a saída esperada. Os demais parâmetros de geração, como a temperatura e a semente aleatória, não foram fixados: cada modelo usou os valores padrão definidos para ele no Ollama, e cada página foi processada uma única vez.

5.3.6 LlamaParse

O LlamaParse foi acessado via API, com a biblioteca oficial `llama-parse`, no modo básico (`parse_page_without_llm`), com o idioma definido como português. A autenticação foi feita por chave de API obtida no portal da LlamaIndex, e cada página foi enviada como um arquivo individual.

5.3.7 Mistral OCR e Gemini

Os adaptadores do Mistral OCR (biblioteca `mistralai`) e do Gemini (biblioteca `google-generativeai`) foram implementados e autenticados por chave de API, enviando a imagem da página com o mesmo *prompt* dos demais VLMs. Os dois modelos, porém, foram excluídos por limites de acesso às APIs, conforme a Seção 5.2.

5.4 PROTOCOLO DE EXTRAÇÃO

5.4.1 Preparação das Páginas

As 20 páginas da amostra (Tabela 5) foram convertidas para PNG na resolução original de cada digitalização, com a biblioteca `pdf2image`. Os PDFs do acervo não são homogêneos: *A Amante Militar* e *O Feliz Independente* foram digitalizados a 300 ppi, com páginas entre 1.030×1.740 e 1.250×2.030 pixels, enquanto *Heloíza* e os dois volumes de *Culto à Mulher* foram digitalizados com um aplicativo de celular a cerca de 150 ppi, com páginas de aproximadamente 900×1.260 pixels. Renderizar estas últimas a 300 ppi apenas ampliaria a imagem, sem

acrescentar detalhe, e aumentaria o custo de processamento dos VLMs, cujo número de *tokens* de entrada cresce com o número de pixels.

Nenhum pré-processamento, como binarização, correção de inclinação ou remoção de ruído, foi aplicado às imagens. Todas as ferramentas receberam as mesmas páginas e foram usadas na configuração padrão, como um usuário do acervo as aplicaria sem ajustes específicos para cada obra. O ganho que o pré-processamento pode trazer, discutido na Seção 3.2, fica como trabalho futuro.

5.4.2 Organização do Código

A implementação foi feita em Python e organizada como um pacote com três partes principais: os adaptadores de modelos OCR (`src/ocr`), o benchmark comparativo (`benchmark`) e a análise dos resultados (`eda`). Todo o código está disponível em repositório público[1].

Os modelos compartilham uma interface comum, definida pela classe abstrata `BaseOCR`, cujo único método obrigatório recebe o caminho de uma imagem e devolve o texto reconhecido. Abaixo dela, três classes intermediárias agrupam os modelos por categoria: `ClassicalOCR`, `TransformerOCR` e `VLMOCR`, esta última responsável pelo *prompt* padronizado usado por todos os modelos de visão-linguagem. Um dicionário (`MODEL_REGISTRY`) associa o nome curto de cada modelo à sua classe, o que permite escolher os modelos a executar por linha de comando e acrescentar novos modelos sem alterar o restante do código.

5.4.3 Extração e Avaliação em Etapas Separadas

O benchmark foi dividido em duas etapas independentes. Na etapa de extração, cada modelo transcreve todas as páginas da amostra, e cada transcrição é salva em um arquivo de texto assim que a página termina. Na etapa de avaliação, essas saídas são comparadas às transcrições de referência. Com essa separação, os modelos são executados uma única vez, e a avaliação pode ser refeita sem reprocessar as páginas, por exemplo após correções na regra ouro ou mudanças na normalização do texto. As saídas obtidas na nuvem entram na avaliação da mesma forma, bastando colocá-las na pasta de resultados.

5.4.4 Medição de Recursos

Nos VLMs locais, a inferência ocorre no servidor do Ollama, que roda como um serviço separado; medir apenas a memória do processo Python subestimaria o custo desses modelos. Por isso, o extrator executa cada modelo em um processo isolado e, a cada meio segundo, registra a memória RAM desse processo e, no caso dos VLMs locais, também a dos processos do Ollama. Para cada página são salvos o tempo de processamento, o pico de memória e o tamanho do texto produzido.

[1] https://github.com/Ewaldouhlmann/tcc-ocr-bu-ufsc

O isolamento por processo também tornou a execução robusta a falhas. Se um modelo é encerrado pelo sistema operacional por falta de memória, os demais seguem normalmente, e a página em que ocorreu a falha fica registrada. Como cada página é salva ao terminar, uma nova execução retoma apenas as páginas pendentes. Erros de limite de requisições das APIs disparam novas tentativas com espera crescente.

5.5 PROTOCOLO DE AVALIAÇÃO

5.5.1 Normalização do Texto

Antes do cálculo das métricas, a referência e a saída de cada modelo passam pela mesma normalização, que remove diferenças de formatação sem relação com o reconhecimento:

- normalização Unicode (forma NFC), para que um mesmo caractere acentuado tenha sempre a mesma representação;
- substituição do *s* longo por *s*, convenção também adotada na regra ouro (Seção 4.5);
- remoção de marcação Markdown e HTML que alguns VLMs acrescentam (títulos, negrito, tabelas);
- junção das palavras hifenizadas no fim da linha;
- unificação das variantes tipográficas de aspas, travessões e reticências;
- remoção do espaço antes de sinais de pontuação, frequente na composição do século XVIII;
- colapso de espaços, tabulações e quebras de linha em um único espaço.

Maiúsculas, acentos e pontuação são mantidos: a fidelidade ortográfica é justamente o que se quer medir.

5.5.2 Métricas e Agregação

O CER e o WER (Seção 2.4) são calculados por página com a biblioteca `jiwer`. Para cada modelo, reportam-se a média das 20 páginas, a média em cada classe de dificuldade e o CER mediano. A mediana complementa a média porque uma única página com erro muito alto pode dominar a média de 20 páginas. Uma página com CER igual ou superior a 50% é contada como **falha**: nesses casos, o texto produzido é inutilizável, seja por saída vazia, repetição em laço ou texto ilegível. Saídas vazias recebem CER e WER de 100%.

5.5.3 Padrões de Erro

Para identificar os tipos de erro, as palavras da referência e da saída de cada modelo, já normalizadas, são alinhadas com a biblioteca `difflib`, e cada substituição de uma palavra por outra é classificada em:

- **acentuação**: as palavras diferem apenas nos diacríticos;
- **pontuação** ou **maiúsculas**: diferem apenas na pontuação adjacente ou na caixa;
- ***s* longo lido como *f***: em *O Feliz Independente*, um *s* impresso na forma longa foi lido como *f* (*deste* → *defte*);
- **grafia modernizada**: a saída é a forma moderna de uma grafia antiga da referência (*espozo* → *esposo*);
- **outros**: demais erros de reconhecimento.

As grafias anteriores às reformas ortográficas são identificadas por um conjunto de regras de reescrita que levam cada forma antiga à moderna, cobrindo os casos mais frequentes no corpus: *hum* e *huma*, *he* por *é*, consoantes dobradas (*elle*, *occasião*), grupos consonantais (*objecto*), o *z* intervocálico da ortografia simplificada do início do século XX (*caza*, *espozo*, *rezultados*), as terminações verbais em *-ão* (*estavão*) e formas como *mãi* e *dahi*. Para cada palavra da referência com grafia antiga, alinhada a uma palavra da saída, verifica-se se o modelo a **preservou**, se a **modernizou** ou se produziu outra forma. As regras são uma aproximação: não cobrem todas as variantes antigas, e a medida se restringe às palavras que o alinhamento conseguiu parear.

5.6 CRITÉRIOS DE SELEÇÃO

A escolha do modelo segue cinco critérios, aplicados na ordem abaixo (Seção 6.5):

1. **Custo e controle dos dados** (eliminatório): o modelo deve poder ser usado sem custo recorrente e sem enviar as imagens do acervo a serviços de OCR de terceiros, o que exclui as APIs pagas e as licenças comerciais. Admite-se o uso de infraestrutura de nuvem genérica, como o Google Colab: nela, o próprio usuário executa um modelo de pesos abertos, com código sob seu controle, e as imagens são processadas em uma máquina virtual temporária vinculada à sua conta, em vez de entregues a um serviço de OCR que as processa em seu nome;
2. **Qualidade**: CER e WER médios e CER mediano;
3. **Robustez**: número de falhas, isto é, páginas com texto inutilizável;

4. **Fidelidade ortográfica**: proporção de grafias antigas preservadas e modernizadas, requisito para uma transcrição fiel ao original;
5. **Viabilidade computacional**: possibilidade de execução no equipamento disponível ou em GPU gratuita na nuvem, e tempo estimado para processar o corpus.

A ordem reflete o uso pretendido: a extração em lote de obras completas, sem revisão página a página. Por isso, a robustez precede a fidelidade ortográfica: uma página inutilizável perde todo o seu texto, enquanto uma grafia modernizada afeta palavras isoladas e pode ser corrigida por uma revisão dirigida aos padrões conhecidos. Quando a fidelidade diplomática for a prioridade, como na preparação de edições críticas, a ordem entre esses dois critérios se inverte, e a recomendação muda (Seção 6.5).

6 RESULTADOS DOS EXPERIMENTOS

Este capítulo apresenta os custos de execução dos modelos (Seção 6.1), a qualidade das transcrições medida contra a regra ouro (Seção 6.2), os padrões de erro observados (Seção 6.3) e a relação entre qualidade e custo (Seção 6.4). Por fim, aplica os critérios da Seção 5.6 para selecionar o modelo (Seção 6.5). Todas as figuras e tabelas deste capítulo são geradas pelo notebook `eda/analise_resultados.ipynb`, a partir das saídas salvas pelo benchmark.

6.1 EXECUÇÃO E CUSTO COMPUTACIONAL

6.1.1 Equipamento sem GPU

Seis modelos foram executados no equipamento descrito na Tabela 6, sobre as 20 páginas da regra ouro (Capítulo 4). A Tabela 9 resume, para cada um, o tempo mediano, mínimo e máximo por página, o pico de memória RAM e o tempo estimado para processar as 1.770 páginas das cinco obras completas.

Tabela 9 – Execução dos modelos sobre as 20 páginas da amostra, no ambiente da Tabela 6.

		Tempo por página (s)		RAM	Projeção
Modelo	**Págs.**	**Mediana**	**Mín.–máx.**	**pico (MB)**	**corpus**
PaddleOCR	20	1,5	0,6–2,6	2.121	47 min
Tesseract	20	1,8	1,1–4,2	197	55 min
DocTR	20	7,0	4,2–12,9	2.680	3,5 h
LlamaParse (básico)	20	8,4	4,8–16,6	181	4,0 h
EasyOCR	20	10,1	6,7–16,1	3.827	5,8 h
GLM-OCR	20	121,8	81,9–303,9	3.044	4,0 dias

Fonte: Elaborado pelo autor.

Os modelos se dividem em dois grupos bem distintos (Figura 6). Os motores clássicos e baseados em CRNN e o LlamaParse processam cada página em segundos: o PaddleOCR e o Tesseract em menos de 2 segundos, e o DocTR, o LlamaParse e o EasyOCR entre 7 e 10 segundos. O GLM-OCR, único VLM executado neste equipamento, levou 2 minutos por página em mediana, com páginas entre 1,4 e 5,1 minutos, uma diferença de duas ordens de grandeza em relação ao primeiro grupo. No caso do LlamaParse, o tempo inclui o envio da imagem e a fila do serviço, e não reflete custo computacional local.

Projetados para as 1.770 páginas, esses tempos resultam em menos de uma hora para o PaddleOCR e o Tesseract, entre 3,5 e 6 horas para o DocTR, o LlamaParse e o EasyOCR, e cerca de 4 dias ininterruptos para o GLM-OCR. A projeção pondera o tempo médio de cada resolução pelo número de páginas do corpus digitalizadas nela.

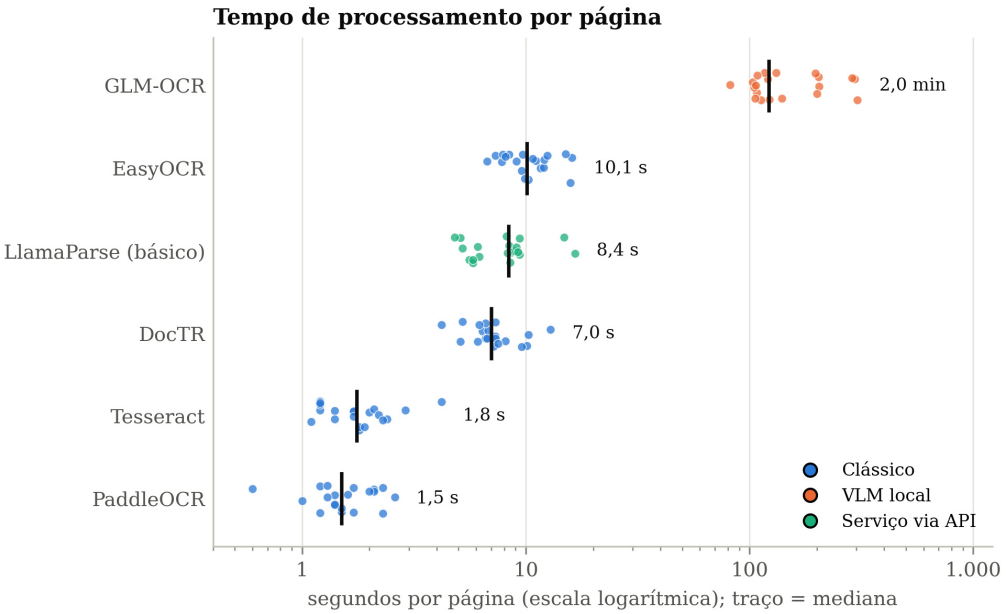


Figura 6 – Tempo de processamento de cada página, por modelo, no equipamento sem GPU. Cada ponto é uma página; o traço vertical marca a mediana.

Fonte: Elaborado pelo autor.

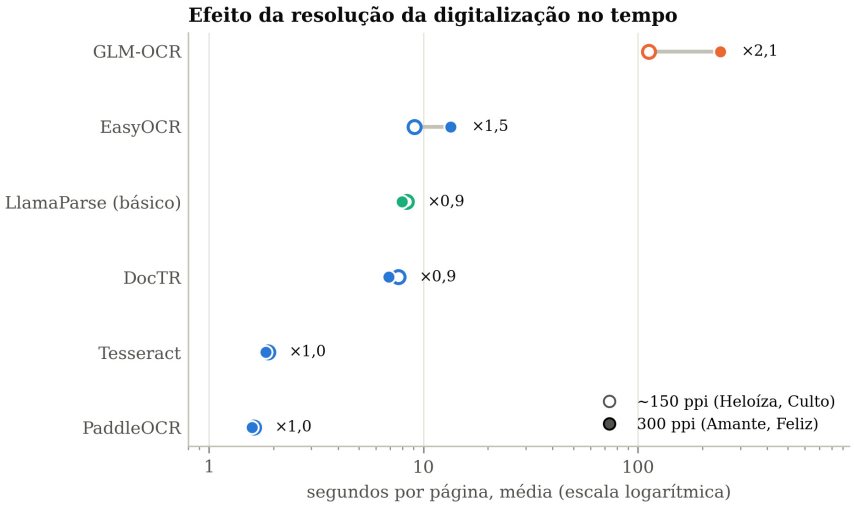


Figura 7 – Tempo médio por página nas digitalizações de cerca de 150 ppi (círculo vazado) e de 300 ppi (círculo cheio), no equipamento sem GPU.

Fonte: Elaborado pelo autor.

A resolução da digitalização afeta os modelos de forma desigual (Figura 7). Nos motores clássicos e no LlamaParse, o tempo praticamente não muda entre as páginas de 150 e de 300 ppi, com exceção do EasyOCR, 1,5 vez mais lento nas de 300 ppi. No GLM-OCR, o efeito é maior: as páginas de 300 ppi levaram 2,1 vezes mais tempo, já que mais pixels geram mais *tokens* de imagem a processar.

O pico de memória ficou abaixo de 4 GB em todos os modelos (Figura 8): o EasyOCR

chegou a 3,8 GB, o GLM-OCR a 3,0 GB e o DocTR a 2,7 GB, enquanto o Tesseract não passou de 200 MB. Como o sistema operacional e o ambiente de desenvolvimento ocupam cerca de 2 GB dos 7,5 GB do equipamento, todos couberam com folga. Para o LlamaParse, o valor corresponde apenas ao cliente local.

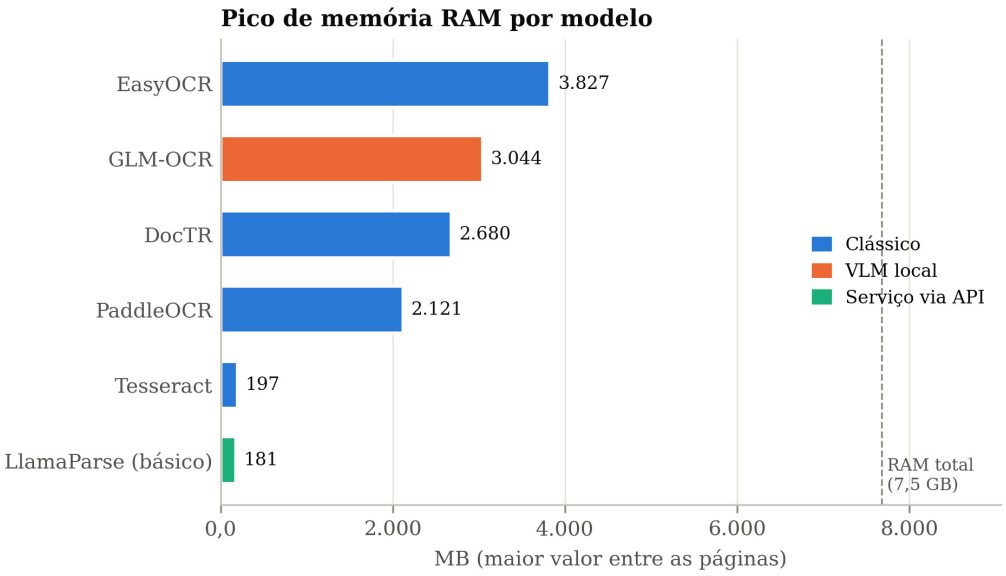


Figura 8 – Pico de memória RAM de cada modelo no equipamento sem GPU, considerando todas as páginas.

Fonte: Elaborado pelo autor.

6.1.2 GPU na Nuvem

Os três VLMs que não cabem no equipamento local (Seção 5.2) foram executados no Google Colab, com GPU T4, em 2 de outubro de 2026. As medianas por página foram de 10,9 s no DeepSeek-OCR, 37,6 s no Qwen2.5-VL 7B e 47,8 s no Gemma 4 E4B, o que projeta, para o corpus completo, cerca de 5, 19 e 24 horas de processamento. Esses tempos foram medidos em outro hardware e servem apenas como referência: não são comparáveis aos da Tabela 9. Na camada gratuita do Colab, as sessões têm duração limitada, e a extração de um corpus desse porte precisa ser dividida em várias sessões, retomando a partir das páginas já salvas.

6.2 QUALIDADE DO RECONHECIMENTO

A Tabela 10 apresenta o CER e o WER de cada modelo, calculados após a normalização descrita na Seção 5.5. Além das médias, a tabela traz o CER mediano e o número de falhas, isto é, de páginas com CER igual ou superior a 50%, nas quais o texto produzido é inutilizável.

Os VLMs locais obtiveram os menores erros. O Qwen2.5-VL 7B teve CER médio de 1,6% e WER de 5,5%, sem nenhuma falha, seguido do Gemma 4 E4B, com 2,2% e 8,8%. O GLM-OCR tem CER médio de 5,6%, mas CER mediano de 0,6%, o menor entre todos

Tabela 10 – CER e WER (%) de cada modelo sobre as 20 páginas da amostra: médias gerais, CER mediano, número de falhas e CER médio por classe de dificuldade.

	Média		CER		CER por dificuldade		
Modelo	**CER**	**WER**	**mediano**	**Falhas**	**Fácil**	**Médio**	**Difícil**
Qwen2.5-VL 7B	1,6	5,5	1,7	0	2,6	1,1	1,6
Gemma 4 E4B	2,2	8,8	1,8	0	2,1	1,4	3,1
GLM-OCR	5,6	8,3	0,6	1	0,2	13,1	0,9
LlamaParse (básico)	5,9	13,3	2,6	0	11,8	4,9	2,9
DocTR	8,7	28,6	7,3	0	10,2	5,9	10,7
ABBYY FineReader	12,8	37,5	7,4	1	10,4	5,6	22,7
EasyOCR	14,9	46,3	15,0	0	13,1	15,8	15,1
Tesseract	18,2	46,0	17,3	0	17,9	24,3	11,5
PaddleOCR	20,3	39,5	14,1	2	24,9	24,9	11,7
DeepSeek-OCR	26,5	31,5	2,1	5	1,9	26,1	44,7

Fonte: Elaborado pelo autor.

Falhas: páginas com CER $\geq 50\%$ (laço de repetição, saída vazia ou texto ilegível).

os modelos. A diferença entre as duas medidas vem de uma única página, em que o modelo entrou em laço de repetição; sem ela, o GLM-OCR fica com CER de 0,6% e WER de 3,3%. O DeepSeek-OCR também tem CER mediano baixo, de 2,1%, mas falhou em cinco páginas, o que eleva sua média para 26,5%.

Entre as demais ferramentas, o LlamaParse ficou com CER de 5,9% e WER de 13,3%, e o DocTR, com 8,7% e 28,6%. O ABBYY FineReader, referência comercial, teve CER de 12,8%, e os outros três motores clássicos, entre 14,9% (EasyOCR) e 20,3% (PaddleOCR). Nesses modelos, o WER chega a quase metade das palavras, 46,0% no Tesseract e 46,3% no EasyOCR: os erros se espalham por muitas palavras, e basta um caractere errado para invalidar a palavra inteira (Seção 2.4).

A Figura 9 mostra o CER de cada página e evidencia que as falhas são isoladas: nos VLMs, quase todas as páginas ficam perto da mediana; nos motores clássicos, o erro varia mais de uma página para outra, mas os valores extremos também se concentram em poucas páginas. As falhas foram de três tipos:

- **laço de repetição**: o GLM-OCR transcreveu corretamente a página 100 do volume 2 de *Culto à Mulher*, mas repetiu o parágrafo inteiro em seguida, o que leva o CER a 100%;
- **saída vazia**: o DeepSeek-OCR devolveu apenas o marcador de fim de resposta em cinco páginas (Culto v1, p. 230; Culto v2, p. 170; Amante, p. 8; Feliz, p. 50 e p. 200);
- **texto ilegível**: o ABBYY produziu uma sequência de caracteres sem sentido na página 8 de *A Amante Militar* (CER de 82%), e o PaddleOCR, nas páginas 130 de *Heloíza* (67%) e 230 do volume 1 de *Culto à Mulher* (59%).

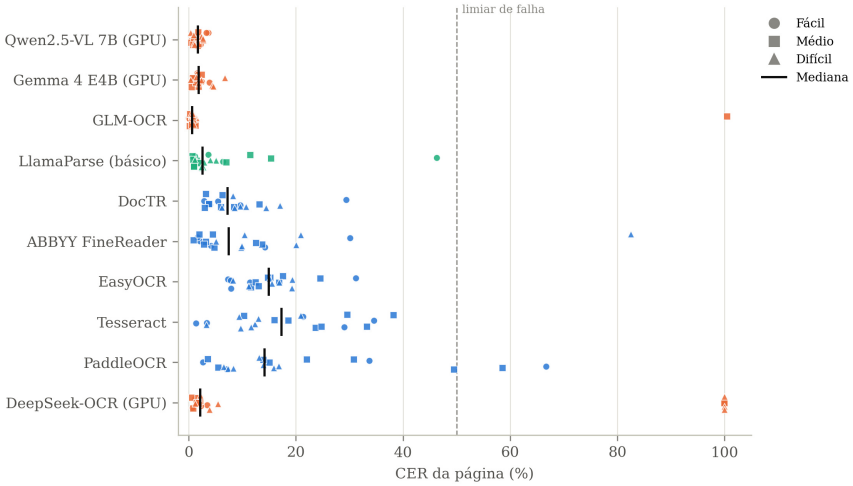


Figura 9 – CER de cada página, por modelo, ordenados pelo CER médio. O formato do marcador indica a classe de dificuldade, e o traço vertical, a mediana do modelo.

Fonte: Elaborado pelo autor.

6.2.1 Desempenho por Obra e Dificuldade

A classificação de dificuldade do Capítulo 4 não se refletiu no erro como esperado (Figura 10). Em metade dos modelos, as páginas classificadas como difíceis, do século XVIII, tiveram CER menor que as de dificuldade média: 11,5% contra 24,3% no Tesseract, 11,7% contra 24,9% no PaddleOCR e 2,9% contra 4,9% no LlamaParse. No Qwen2.5-VL 7B e no Gemma 4 E4B, a diferença entre as três classes ficou abaixo de dois pontos percentuais. Somente no ABBYY (22,7%) e no DeepSeek-OCR, que teve três de suas cinco saídas vazias nessas páginas, as difíceis foram claramente as piores. A classe fácil também não foi a de menor erro em vários modelos: no LlamaParse, no DocTR e no ABBYY, as páginas de *Heloíza* tiveram CER maior que as de *Culto à Mulher*.

A Figura 11, com o CER de cada página, ajuda a explicar o resultado. As obras do século XVIII foram digitalizadas com *scanner* a 300 ppi, com fundo uniforme e bom contraste; já *Heloíza* e os volumes de *Culto à Mulher* foram fotografados com celular a cerca de 150 ppi, com sombras, curvatura e manchas. A página 130 de *Heloíza*, fotografada com forte curvatura, elevou o erro de quase todos os modelos clássicos (entre 29% e 67%) e do LlamaParse (46%), embora seja de uma obra classificada como fácil. Nesses modelos, a qualidade da digitalização pesou mais no erro do que a idade da tipografia, ponto retomado no Capítulo 7.

6.3 PADRÕES DE ERRO E FIDELIDADE ORTOGRÁFICA

A Tabela 11 resume os tipos de erro de cada modelo, segundo a classificação da Seção 5.5.

Nos motores clássicos, predominam erros visuais. O DocTR e o PaddleOCR erraram

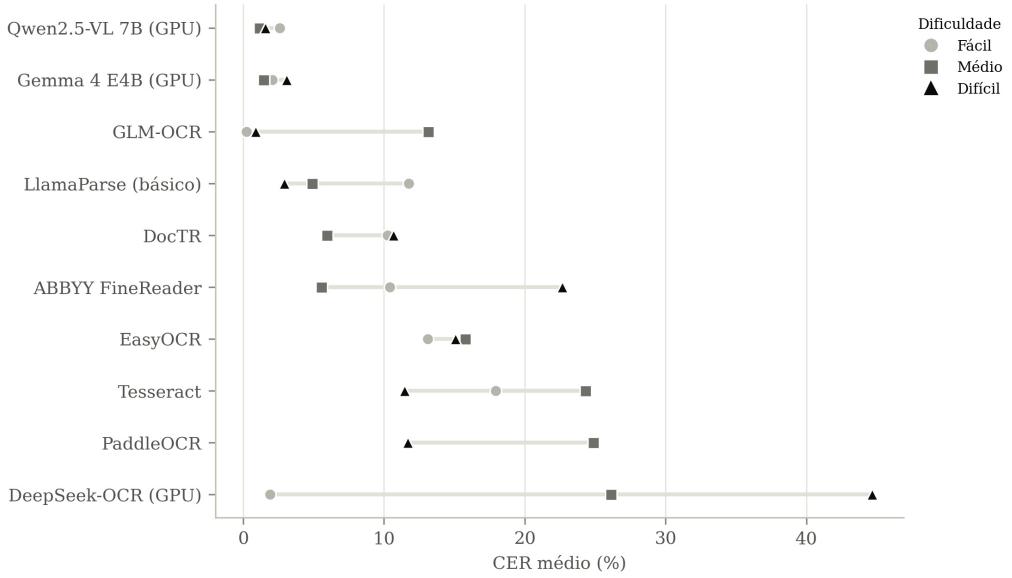


Figura 10 – CER médio de cada modelo por classe de dificuldade.

Fonte: Elaborado pelo autor.

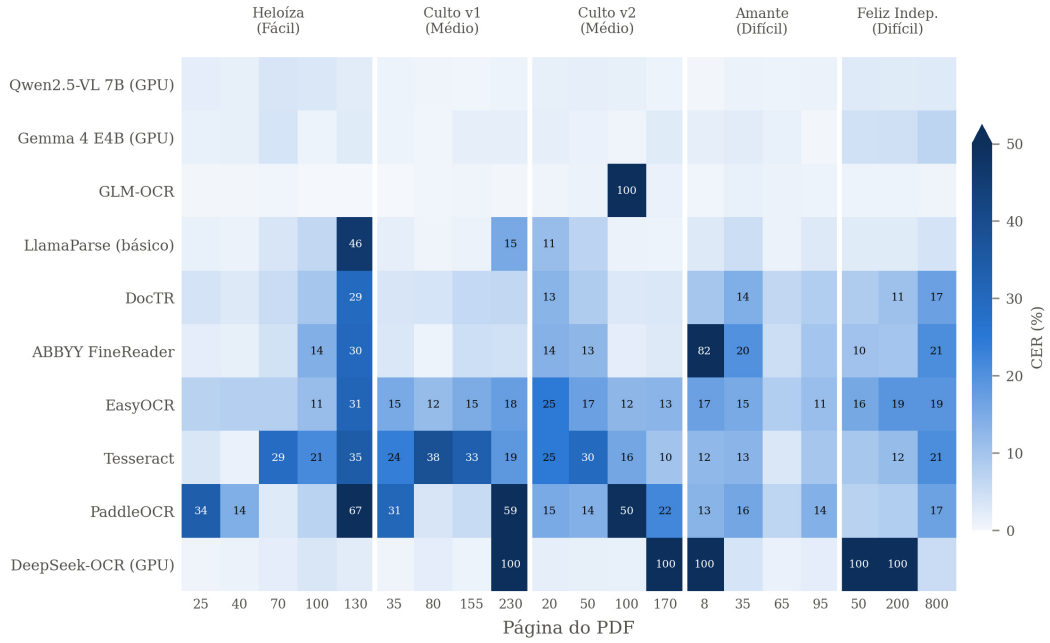


Figura 11 – CER de cada modelo (linhas) em cada página (colunas), agrupadas por obra. Os valores a partir de 10% estão escritos na célula; a escala de cor satura em 50%.

Fonte: Elaborado pelo autor.

apenas a acentuação em 214 e 190 palavras, respectivamente, e o EasyOCR errou a pontuação em 210. Em *O Feliz Independente*, o *s* longo foi lido como *f* 62 vezes pelo PaddleOCR, 54 pelo DocTR, 48 pelo Tesseract e 46 pelo ABBYY, produzindo formas como *defte* e *fua*. Esses modelos não modernizam: quando erram uma grafia antiga, produzem uma forma inexistente, não a forma moderna. Entre os VLMs, a confusão do *s* longo foi bem menos frequente (9 casos

Tabela 11 – Padrões de erro por modelo: substituições de palavras por tipo e tratamento das grafias anteriores às reformas ortográficas.

		Substituições de palavras				Grafias antigas (%)	
Modelo	**Total**	**Acent.**	**Pont.**	**s→f**	**Modern.**	**Preserv.**	**Modern.**
Qwen2.5-VL 7B	164	72	13	12	19	83,1	12,3
Gemma 4 E4B	290	100	18	60	41	59,5	26,8
GLM-OCR	112	46	13	9	5	88,3	3,2
LlamaParse (básico)	216	17	73	10	0	91,7	0,0
DocTR	558	214	53	54	0	69,5	0,0
ABBYY FineReader	348	63	41	46	0	75,0	0,0
EasyOCR	657	31	210	14	2	72,4	1,7
Tesseract	289	31	74	48	0	86,1	0,0
PaddleOCR	460	190	78	62	0	69,2	0,0
DeepSeek-OCR	168	66	19	24	5	77,3	5,7

Fonte: Elaborado pelo autor.

s→f: *s* longo lido como *f*, contado só em *O Feliz Independente*. Grafias antigas: palavras da regra ouro identificadas pelas regras da Seção 5.5, entre as alinhadas uma a uma com a saída do modelo.

no GLM-OCR e 12 no Qwen2.5-VL 7B), com exceção do Gemma 4 E4B, com 60.

Os VLMs, por outro lado, concentraram a modernização de grafias, como antecipado por Vesalainen et al. (14) (Figura 12). O Gemma 4 E4B modernizou 26,8% das palavras com grafia antiga (*ezistencia* → *existência*, *espozo* → *esposo*, *rezignação* → *resignação*, *cazamento* → *casamento*), e o Qwen2.5-VL 7B, 12,3% (*dezesperos* → *desesperos*, *religioza* → *religiosa*, *mãi* → *mãe*). No GLM-OCR, a proporção foi de 3,2% (*alli* → *ali*, *differente* → *diferente*, *occasião* → *ocasião*), e no DeepSeek-OCR, de 5,7%. Esse erro é silencioso: o texto resultante é fluente e não aparenta erro, o que o torna difícil de detectar em uma revisão, ao contrário de um laço de repetição ou de uma página vazia.

A maior preservação das grafias antigas foi a do LlamaParse (91,7%), seguido do GLM-OCR (88,3%) e do Tesseract (86,1%). O Qwen2.5-VL 7B preservou 83,1%, e o Gemma 4 E4B, 59,5%. Nos motores clássicos, a preservação é limitada pelos erros de reconhecimento, não pela modernização.

6.4 QUALIDADE E CUSTO

A Figura 13 cruza o CER médio com o custo de execução. Nenhum modelo é melhor em tudo: os motores clássicos são rápidos e leves, mas erram mais; os VLMs erram menos, mas são lentos em CPU ou dependem de GPU. Entre os modelos que processam a página no próprio equipamento sem GPU, o GLM-OCR é o único com CER abaixo de 6%, ao custo de cerca de 2 minutos por página e 3 GB de memória. O Qwen2.5-VL 7B e o Gemma 4 E4B têm CER médio menor, mas só puderam ser executados em GPU. O LlamaParse combina erro baixo

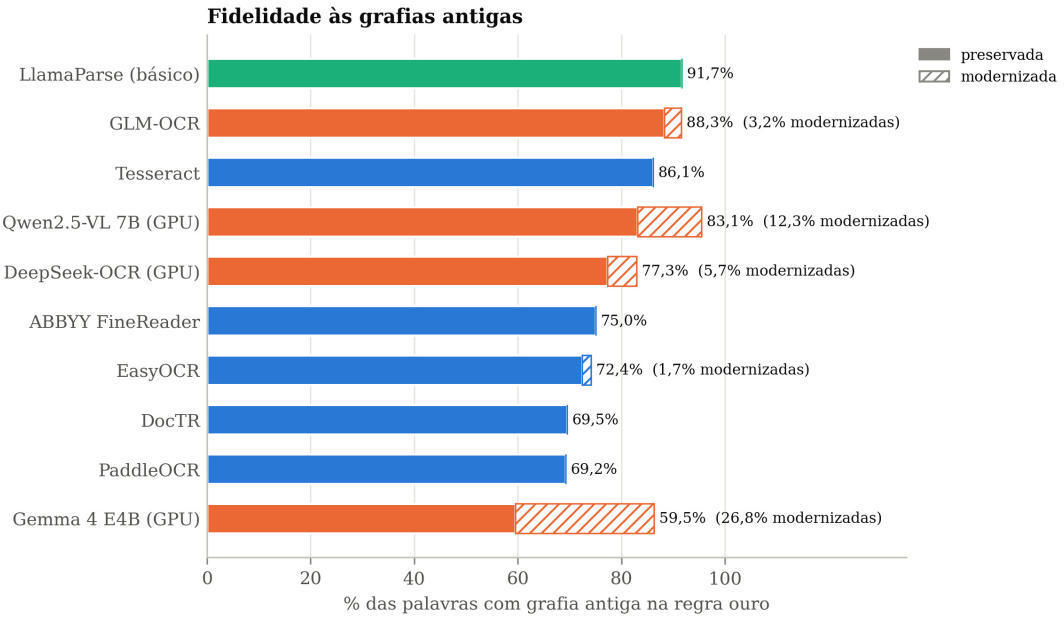


Figura 12 – Proporção das palavras com grafia antiga na regra ouro que cada modelo preservou (barra cheia) e que modernizou (barra hachurada). O restante corresponde a outros erros de reconhecimento.

Fonte: Elaborado pelo autor.

e custo local quase nulo porque o processamento ocorre no provedor, com custo por página e envio das imagens a terceiros.

6.5 SELEÇÃO DO MODELO

Os critérios da Seção 5.6 foram aplicados em ordem.

Custo e controle dos dados. O LlamaParse cobra por página e exige o envio das imagens a um serviço de terceiros, e o ABBYY depende de licença comercial para ser aplicado a novas digitalizações; os dois foram eliminados. Restaram os quatro motores clássicos de código aberto e os quatro VLMs locais.

Qualidade. Os VLMs locais, desconsideradas as falhas, ficaram com CER entre 0,6% e 2,2%, contra 8,7% a 18,2% dos motores clássicos (Tabela 10). A diferença é grande o bastante para eliminar os motores clássicos, restando o GLM-OCR, o Qwen2.5-VL 7B, o Gemma 4 E4B e o DeepSeek-OCR.

Robustez. O DeepSeek-OCR falhou em 5 das 20 páginas, um quarto da amostra, e foi eliminado. O GLM-OCR falhou em uma página, por laço de repetição; o Qwen2.5-VL 7B e o Gemma 4 E4B não falharam.

Fidelidade ortográfica. O Gemma 4 E4B modernizou mais de um quarto das grafias antigas (26,8%), mais que o dobro de qualquer outro VLM, e foi eliminado.

A decisão ficou entre o GLM-OCR e o Qwen2.5-VL 7B, comparados na Tabela 12.

Com base nessa comparação, foi selecionado o **Qwen2.5-VL 7B**. Três razões sustentam a escolha:

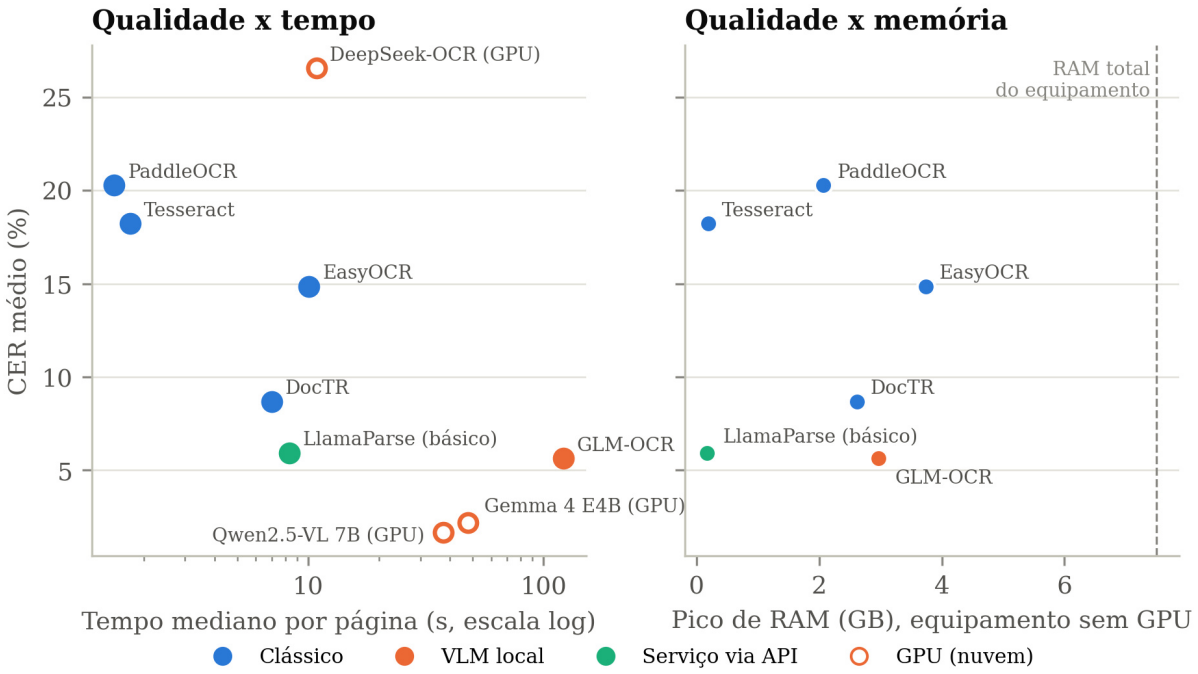


Figura 13 – CER médio de cada modelo em função do tempo mediano por página (esquerda) e do pico de memória RAM no equipamento sem GPU (direita). Marcadores vazados indicam modelos executados em GPU na nuvem, cujo tempo foi medido em outro hardware.

Fonte: Elaborado pelo autor.

Tabela 12 – Comparação final entre os dois modelos candidatos.

Indicador	**GLM-OCR**	**Qwen2.5-VL 7B**
CER médio / WER médio (%)	5,6 / 8,3	1,6 / 5,5
CER mediano (%)	0,6	1,7
CER / WER sem as falhas (%)	0,6 / 3,3	1,6 / 5,5
Falhas (páginas)	1	0
Grafias antigas preservadas / modernizadas (%)	88,3 / 3,2	83,1 / 12,3
Hardware necessário	CPU, 3,0 GB de RAM	GPU
Tempo mediano por página	2 min (CPU)	38 s (GPU T4)
Tempo projetado para o corpus	cerca de 4 dias	cerca de 19 h

Fonte: Elaborado pelo autor.

1. obteve o menor erro médio considerando todas as páginas, com CER de 1,6% e WER de 5,5%, contra 5,6% e 8,3% do GLM-OCR. A média sobre todas as páginas é a medida que interessa a uma extração em lote, pois inclui as páginas em que o modelo falha;

2. não falhou em nenhuma página e teve desempenho estável entre as classes de dificuldade, com CER entre 1,1% e 2,6%. O GLM-OCR entrou em laço de repetição em uma das 20

páginas; mantida essa frequência, seriam cerca de 90 páginas inutilizáveis no corpus, que precisariam ser identificadas e reprocessadas;

3. embora dependa de GPU, roda separado do equipamento do NUPILL, na camada gratuita do Google Colab, por meio do notebook do Apêndice A, sem custo financeiro e sem enviar as imagens a um serviço de OCR de terceiros. Nesse ambiente, o corpus completo leva cerca de 19 horas, contra cerca de 4 dias do GLM-OCR em CPU.

Além disso, por ser a mesma variante avaliada por Vesalainen et al. (14), os resultados deste trabalho podem ser comparados diretamente com os daquele estudo.

O custo da escolha é a fidelidade ortográfica: o Qwen2.5-VL 7B modernizou 12,3% das grafias antigas, cerca de uma em cada oito, contra 3,2% do GLM-OCR. A modernização se concentrou em padrões previsíveis, sobretudo o *z* intervocálico da ortografia do início do século XX (*espozo*, *cazamento*, *dezesperos*) e formas como *mãi*, o que permite uma revisão dirigida a esses padrões. O GLM-OCR permanece como alternativa quando não houver GPU disponível ou quando a fidelidade diplomática for a prioridade, como na preparação de edições críticas, desde que acompanhado da detecção e do reprocessamento de laços de repetição. O resultado confirma a expectativa formada a partir da literatura: o Qwen2.5-VL, apontado por Vesalainen et al. (14), obteve o menor erro médio, e a tendência à modernização relatada pelos autores também se confirmou no português.

A escolha tem limitações. Com 20 páginas, uma única falha não permite estimar com precisão a frequência de laços de repetição no corpus completo; a regra ouro foi transcrita por uma única pessoa; e as regras de identificação de grafias antigas são uma aproximação. Essas e outras limitações do estudo estão reunidas na Seção 7.1.

7 CONCLUSÃO

Este trabalho avaliou ferramentas de reconhecimento óptico de caracteres aplicadas a obras literárias impressas em português entre os séculos XVIII e XX, do acervo do NUPILL, com o objetivo de selecionar a mais adequada à digitalização desse acervo. Os objetivos específicos foram cumpridos: a revisão bibliográfica (Capítulos 2 e 3) orientou a escolha de ferramentas candidatas de quatro gerações tecnológicas, das quais três foram avaliadas; a regra ouro, com 20 páginas de cinco obras estratificadas por dificuldade, foi construída e revisada manualmente (Capítulo 4); dez ferramentas foram executadas sobre essa amostra, com registro de tempo e memória (Seção 6.1); a comparação considerou CER, WER, robustez, fidelidade às grafias antigas e custo (Seções 6.2 a 6.4); os padrões de erro foram identificados (Seção 6.3); e um modelo foi selecionado segundo os critérios da Seção 5.6 (Seção 6.5).

A primeira conclusão é que, nesse tipo de material, os modelos de visão-linguagem superam com folga os motores de OCR clássicos e baseados em redes neurais. Desconsideradas as páginas em que falharam, os VLMs avaliados ficaram com CER médio entre 0,6% e 2,2%, enquanto os motores clássicos de código aberto ficaram entre 8,7% e 18,2%. O texto gerado pelo ABBYY FineReader, já presente nos PDFs do acervo, teve CER de 12,8%, cerca de oito vezes o do modelo selecionado. Isso indica que reprocessar as imagens já digitalizadas do NUPILL com um VLM pode melhorar bastante o texto disponível, sem nova digitalização.

A segunda conclusão é que o CER não basta para escolher uma ferramenta para obras históricas, porque as duas famílias de modelos erram de formas diferentes. Os motores clássicos cometem erros visuais, como a troca de acentos, de pontuação e do *s* longo por *f*, e produzem palavras inexistentes, fáceis de localizar em uma revisão. Os VLMs erram menos, mas de duas maneiras mais difíceis de detectar: modernizam grafias antigas sem sinalizar a mudança e, ocasionalmente, falham em uma página inteira, por laço de repetição ou saída vazia. Em acervos literários, nos quais a grafia original faz parte do objeto de estudo, a robustez e a fidelidade ortográfica precisam ser medidas ao lado das taxas de erro.

A terceira conclusão, e a mais relevante para a digitalização de obras históricas, é que a instrução explícita de preservar a grafia original não impediu a modernização. O Qwen2.5-VL 7B e o Gemma 4 E4B, modelos de uso geral, receberam um *prompt* que pedia a transcrição fiel, com a ortografia, a acentuação e a pontuação originais, mesmo que arcaicas, e que dizia explicitamente "Não modernize grafias históricas" (Apêndice B). Ainda assim, modernizaram 12,3% e 26,8% das palavras com grafia antiga, como *espozo* → *esposo* e *mãi* → *mãe*. O GLM-OCR e o DeepSeek-OCR, especializados em OCR e que receberam apenas as instruções fixas de tarefa previstas por seus desenvolvedores, modernizaram 3,2% e 5,7%. Como os modelos diferem em arquitetura e em dados de treinamento, essa comparação não isola o efeito do *prompt*. Ela mostra, porém, que a normalização ortográfica relatada por Vesalainen et al. (14) em inglês também ocorre em português e não é contida por uma instrução no *prompt*. A fidelidade diplomática de uma transcrição feita por VLM precisa, portanto, ser verificada na saída, e não presumida a partir da instrução dada ao modelo.

A quarta conclusão, mais limitada, é que a idade da tipografia não determinou sozinha a dificuldade das páginas. No Tesseract, no PaddleOCR e no LlamaParse, as obras do século XVIII, digitalizadas com *scanner* a 300 ppi, tiveram erro menor que as do século XX, fotografadas com celular a cerca de 150 ppi, e a página com maior erro de quase todos os motores clássicos foi uma fotografia com forte curvatura de uma obra classificada como fácil (Seção 6.2.1). Como, neste corpus, a época da obra e a forma de digitalização coincidem, não é possível separar os dois efeitos; os resultados indicam, porém, que a redigitalização das obras fotografadas é um caminho promissor para melhorar o resultado de qualquer ferramenta.

Com base nos critérios definidos, foi selecionado o Qwen2.5-VL 7B, que obteve o menor erro médio considerando todas as páginas, com CER de 1,6% e WER de 5,5%, sem nenhuma falha. A escolha tem dois custos: o modelo modernizou 12,3% das grafias antigas e depende de GPU, disponível gratuitamente no Google Colab. O GLM-OCR permanece como alternativa quando não houver GPU disponível ou quando a fidelidade diplomática for prioritária, desde que acompanhado da detecção de laços de repetição. Ambos podem ser executados sem custo financeiro, o que torna a extração de texto de acervos como o do NUPILL viável com os recursos de que núcleos de pesquisa costumam dispor. O pipeline de extração e o notebook do Apêndice A permitem aplicar o modelo escolhido a obras completas.

Esses resultados devem ser lidos à luz das limitações apresentadas a seguir. A diferença entre as famílias de modelos, porém, é grande o bastante para orientar a escolha de ferramentas em projetos semelhantes.

7.1 LIMITAÇÕES

- **Tamanho da amostra**: a avaliação usou 20 páginas e uma execução por modelo. Diferenças pequenas entre modelos, como a do Qwen2.5-VL 7B (CER de 1,6%) para o Gemma 4 E4B (2,2%), não são conclusivas, e uma única falha não permite estimar a frequência de laços de repetição no corpus completo.

- **Classificação de dificuldade**: embora feita por página, coincidiu com a obra de origem, e a época das obras coincidiu com a forma de digitalização. Por isso, o efeito da tipografia não pode ser separado do efeito da qualidade da imagem.

- **Regra ouro**: foi transcrita por uma única pessoa, com apoio do NUPILL nas passagens incertas, sem uma segunda transcrição independente que permita medir a concordância entre transcritores.

- **Medida de fidelidade**: as regras que identificam grafias antigas são uma aproximação e só consideram as palavras que o alinhamento conseguiu parear.

- **Execução única**: cada página foi processada uma única vez, com os parâmetros de amostragem padrão de cada modelo. Execuções repetidas podem produzir transcrições diferentes, inclusive quanto à ocorrência de laços de repetição.

- **Comparação de custo**: os tempos dos VLMs executados na nuvem foram medidos em outro hardware e não são diretamente comparáveis aos do equipamento local.

7.2 TRABALHOS FUTUROS

1. Aplicar o pipeline de extração (Apêndice A) às obras do acervo do NUPILL e avaliar a qualidade em uma amostra maior das páginas extraídas.
2. Detectar automaticamente laços de repetição e saídas vazias, reprocessando as páginas afetadas com outro modelo ou outros parâmetros.
3. Avaliar a pós-correção do texto com modelos de linguagem (39), verificando se ela preserva as grafias antigas.
4. Investigar formas de conter a modernização ortográfica dos VLMs, como *prompts* com exemplos de grafias antigas, restrição da decodificação a palavras presentes na imagem ou ajuste fino com textos da época, medindo o efeito de cada uma com a métrica de fidelidade proposta neste trabalho.
5. Ampliar a regra ouro com mais páginas e um segundo transcritor, para medir a concordância entre transcrições.
6. Redigitalizar a 300 ppi as obras fotografadas com celular e medir o ganho de qualidade.
7. Avaliar o efeito do pré-processamento das imagens, como binarização e correção de curvatura, sobre os motores clássicos e os VLMs.

REFERÊNCIAS

1 TERRAS, M. Digitization and digital resources in the humanities. In: WARWICK, C.; TERRAS, M.; NYHAN, J. (Ed.). **Digital Humanities in Practice**. London: Facet Publishing, 2012. cap. 3, p. 47–70. Disponível em: https://www.cambridge.org/core/books/abs/digital-humanities-in-practice/digitization-and-digital-resources-in-the-humanities/D82569EC95F1F6C17442F14EDBA357AD. Acesso em: 01 jul. 2026.

2 SANTOS, M. K. et al. ESTER-Pt: An evaluation suite for TExt recognition in portuguese. In: FINK, G. A. et al. (Ed.). **Document Analysis and Recognition – ICDAR 2023**. Cham: Springer Nature Switzerland, 2023. p. 366–383. Disponível em: https://doi.org/10.1007/978-3-031-41682-8_23. Acesso em: 01 jul. 2026.

3 BURDICK, A. et al. **Digital Humanities**. Cambridge: MIT Press, 2012. Disponível em: https://direct.mit.edu/books/book/5346/Digital-Humanities. Acesso em: 01 jul. 2026.

4 LI, M. et al. TrOCR: Transformer-based optical character recognition with pre-trained models. In: **Proceedings of the AAAI Conference on Artificial Intelligence**. [s.n.], 2023. v. 37, n. 11, p. 13094–13102. Disponível em: https://doi.org/10.1609/aaai.v37i11.26538. Acesso em: 09 maio 2026.

5 Qwen Team. **Qwen2.5-VL Technical Report**. 2025. ArXiv preprint arXiv:2502.13923. Disponível em: https://arxiv.org/abs/2502.13923. Acesso em: 14 maio 2026.

6 SMITH, D. A.; CORDELL, R. **A Research Agenda for Historical and Multilingual Optical Character Recognition**. Boston, 2018. Disponível em: https://ocr.northeastern.edu/report/. Acesso em: 09 maio 2026.

7 MORI, S.; SUEN, C. Y.; YAMAMOTO, K. Historical review of OCR research and development. **Proceedings of the IEEE**, v. 80, n. 7, p. 1029–1058, 1992.

8 LOMBARDI, F.; MARINAI, S. Deep learning for historical document analysis and recognition: a survey. **Journal of Imaging**, v. 6, n. 10, p. 110, out. 2020. Disponível em: https://doi.org/10.3390/jimaging6100110. Acesso em: 01 jul. 2026.

9 AL-HASSANI, M. D. **Optical Character Recognition (OCR) System for Multifont English Texts Using DCT & Wavelet Transform**. 2013. ResearchGate. Disponível em: https://www.researchgate.net/figure/Figure-1-Block-Diagram-of-the-Proposed-OCR-System-Model_fig1_260405352. Acesso em: 29 abr. 2026.

10 SHI, B.; BAI, X.; YAO, C. An end-to-end trainable neural network for image-based sequence recognition and its application to scene text recognition. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, v. 39, n. 11, p. 2298–2304, 2017.

11 HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. **Neural Computation**, v. 9, n. 8, p. 1735–1780, 1997.

12 VASWANI, A. et al. Attention is all you need. In: **Advances in Neural Information Processing Systems 30 (NeurIPS)**. [S.l.]: Curran Associates, 2017. p. 5998–6008.

13 DOSOVITSKIY, A. et al. An image is worth 16x16 words: Transformers for image recognition at scale. In: **Proceedings of the 9th International Conference on Learning Representations (ICLR)**. [s.n.], 2021. Disponível em: https://openreview.net/forum?id=YicbFdNTTy.

14 VESALAINEN, A. et al. **Error patterns in historical OCR: a comparative analysis of TrOCR and a vision-language model**. 2026. ArXiv preprint arXiv:2602.14524. Disponível em: https://arxiv.org/abs/2602.14524. Acesso em: 05 maio 2026.

15 SMITH, R. An overview of the Tesseract OCR engine. In: **Proceedings of the 9th International Conference on Document Analysis and Recognition (ICDAR)**. Curitiba: IEEE, 2007. p. 629–633. Disponível em: https://doi.org/10.1109/ICDAR.2007.4376991. Acesso em: 21 out. 2026.

16 JaidedAI. **EasyOCR: Ready-to-use OCR with 80+ supported languages**. 2020. JaidedAI. Disponível em: https://github.com/JaidedAI/EasyOCR. Acesso em: 14 maio 2026.

17 BAEK, Y. et al. Character region awareness for text detection. In: **Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)**. [S.l.]: IEEE, 2019. p. 9365–9374.

18 GRAVES, A. et al. Connectionist temporal classification: labelling unsegmented sequence data with recurrent neural networks. In: **Proceedings of the 23rd International Conference on Machine Learning (ICML)**. New York: ACM, 2006. p. 369–376.

19 Baidu. **PaddleOCR: Awesome multilingual OCR toolkits based on PaddlePaddle**. 2022. PaddlePaddle. Disponível em: https://github.com/PaddlePaddle/PaddleOCR. Acesso em: 14 maio 2026.

20 Mindee. **docTR: Document Text Recognition**. 2021. Mindee. Disponível em: https://github.com/mindee/doctr. Acesso em: 14 maio 2026.

21 LIAO, M. et al. Real-time scene text detection with differentiable binarization. In: **Proceedings of the AAAI Conference on Artificial Intelligence**. [S.l.: s.n.], 2020. v. 34, n. 7, p. 11474–11481.

22 CHAURASIA, A.; CULURCIELLO, E. LinkNet: exploiting encoder representations for efficient semantic segmentation. In: **Proceedings of the IEEE Visual Communications and Image Processing (VCIP)**. [S.l.]: IEEE, 2017. p. 1–4.

23 LI, H. et al. Show, attend and read: a simple and strong baseline for irregular text recognition. In: **Proceedings of the AAAI Conference on Artificial Intelligence**. [S.l.: s.n.], 2019. v. 33, n. 1, p. 8610–8617.

24 Ollama. **Ollama: Run large language models locally**. 2023. Ollama. Disponível em: https://ollama.com. Acesso em: 14 maio 2026.

25 Google DeepMind. **Gemma 4 Model Card**. 2026. Google DeepMind. Disponível em: https://ai.google.dev/gemma/docs/core/model_card_4. Acesso em: 29 maio 2026.

26 WU, Z. et al. **DeepSeek-VL2: Mixture-of-Experts Vision-Language Models for Advanced Multimodal Understanding**. 2024. ArXiv preprint arXiv:2412.10302. Disponível em: https://arxiv.org/abs/2412.10302. Acesso em: 14 maio 2026.

27 WEI, H.; SUN, Y.; LI, Y. **DeepSeek-OCR: contexts optical compression**. 2025. ArXiv preprint arXiv:2510.18234. Disponível em: https://arxiv.org/abs/2510.18234.

28 DUAN, S. et al. **GLM-OCR technical report**. 2026. ArXiv preprint arXiv:2603.10910. Disponível em: https://arxiv.org/abs/2603.10910.

29 Ollama. **glm-ocr**. 2026. Biblioteca de modelos do Ollama. Disponível em: https://ollama.com/library/glm-ocr. Acesso em: 26 set. 2026.

30 LlamaIndex. **LlamaParse Pricing**. 2025. LlamaIndex. Disponível em: https://www.llamaindex.ai/pricing. Acesso em: 14 maio 2026.

31 Mistral AI. **Mistral OCR**. 2025. Mistral AI. Disponível em: https://mistral.ai/news/mistral-ocr. Acesso em: 14 maio 2026.

32 Google. **Gemini API Pricing**. Mountain View: [s.n.], 2025. Disponível em: https://ai.google.dev/gemini-api/docs/pricing. Acesso em: 14 maio 2026.

33 ABBYY. **ABBYY FineReader PDF**. 2026. Software comercial de OCR. Disponível em: https://pdf.abbyy.com. Acesso em: 12 out. 2026.

34 NEUDECKER, C. et al. A survey of OCR evaluation tools and metrics. In: **Proceedings of the 6th International Workshop on Historical Document Imaging and Processing (HIP)**. Lausanne: ACM, 2021. p. 13–18.

35 LEVENSHTEIN, V. I. Binary codes capable of correcting deletions, insertions, and reversals. **Soviet Physics Doklady**, v. 10, n. 8, p. 707–710, 1966.

36 MORRIS, A. C.; MAIER, V.; GREEN, P. From WER and RIL to MER and WIL: improved evaluation measures for connected speech recognition. In: **Proceedings of the 8th International Conference on Spoken Language Processing (INTERSPEECH)**. ISCA, 2004. p. 2765–2768. Disponível em: https://doi.org/10.21437/Interspeech.2004-668. Acesso em: 01 jul. 2026.

37 THENNAL, D. K. et al. **Advocating Character Error Rate for Multilingual ASR Evaluation**. 2025. Findings of the Association for Computational Linguistics: NAACL 2025. Disponível em: https://arxiv.org/abs/2410.07400. Acesso em: 01 jul. 2026.

38 ANVARI, Z.; ATHITSOS, V. **A survey on deep learning based document image enhancement**. 2021. ArXiv preprint arXiv:2112.02719. Disponível em: https://arxiv.org/abs/2112.02719. Acesso em: 05 maio 2026.

39 FRITZEN, V. J. **Avaliação do uso de modelos de linguagem de larga escala para correção pós-reconhecimento óptico de caracteres em língua portuguesa**. Trabalho de Conclusão de Curso (Bacharelado em Ciência da Computação) — Universidade Federal do Rio Grande do Sul, Porto Alegre, 2025. Orientador: Dennis Giovani Balreira. Disponível em: https://hdl.handle.net/10183/300245. Acesso em: 01 jul. 2026.

40 ROSA, M. A. P. d. S. et al. Utilizando ferramentas de OCR para ler documentos históricos manuscritos em português: um estudo de caso. **Caderno Pedagógico**, Curitiba, v. 22, n. 4, p. 1–13, 2025. Disponível em: https://doi.org/10.54033/cadped.v22i4.14144. Acesso em: 01 jul. 2026.

41 AGUILAR, S. T.; JOLIVET, V. Digital technologies for early modern portuguese manuscripts: an experiment with two handwritten text recognition software applications. **Digital Scholarship in the Humanities**, Oxford, v. 41, n. 1, p. 255–270, 2024. Disponível em: https://doi.org/10.1093/llc/fqae088. Acesso em: 01 jul. 2026.

42 BAUDRY, H. **TraPrInq: transcrição automática de processos da Inquisição portuguesa com Transkribus**. 2023. Blog Transkribus (READ-COOP). Disponível em: https://www.transkribus.org/blog/portuguese-inquisition-herve-baudry-traprinq. Acesso em: 22 maio 2026.

43 Google. **Google Colaboratory**. 2026. Ambiente de notebooks Jupyter hospedado. Disponível em: https://colab.research.google.com. Acesso em: 2 out. 2026.

44 Ollama. **gemma4: tags**. 2026. Biblioteca de modelos do Ollama. Disponível em: https://ollama.com/library/gemma4/tags. Acesso em: 25 set. 2026.

45 Ollama. **deepseek-ocr: tags**. 2026. Biblioteca de modelos do Ollama. Disponível em: https://ollama.com/library/deepseek-ocr/tags. Acesso em: 26 set. 2026.

APÊNDICE A – PIPELINE DE EXTRAÇÃO

Como contribuição complementar, o trabalho disponibiliza um pipeline que aplica o modelo escolhido, ou qualquer outro dos avaliados, a um livro inteiro em PDF. O pipeline (`src/pipeline/extractor.py`) processa uma página por vez, nas etapas da Figura 14: renderiza a página do PDF em imagem, envia a imagem ao modelo e salva o texto. Cada página é salva assim que termina, e uma nova execução retoma apenas as pendentes, o que permite processar livros longos em várias sessões. Falhas em uma página são registradas sem interromper o livro.

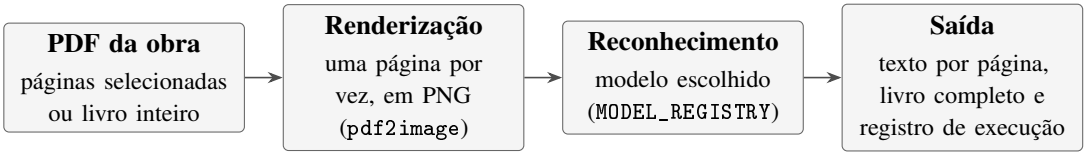


Figura 14 – Etapas do pipeline de extração.

Fonte: Elaborado pelo autor.

Para cada livro, o pipeline gera um arquivo de texto por página, um arquivo com o livro completo, no qual cada página é precedida de um marcador com seu número, e um registro com o tempo, o número de caracteres e os *tokens* de cada página. Ele é executado por linha de comando, informando o PDF, o modelo, a pasta de saída e, opcionalmente, as páginas e a resolução de renderização.

Para quem não dispõe de GPU, o repositório inclui também um notebook para o Google Colab (`notebooks/pipeline_colab.ipynb`). Em um formulário, o usuário escolhe o modelo, o PDF guardado no Google Drive e as páginas; o notebook baixa o código do repositório, instala apenas as dependências do modelo escolhido, inicia o Ollama quando necessário e salva os resultados no Drive. As chaves dos serviços via API, quando usadas, são lidas dos *Secrets* do Colab, sem ficarem escritas no notebook. O texto produzido não passa por revisão: para uso acadêmico, recomenda-se conferi-lo contra as imagens, em especial quanto aos laços de repetição e à modernização de grafias descritos no Capítulo 6.

APÊNDICE B – PROMPT DOS MODELOS DE VISÃO-LINGUAGEM

O *prompt* abaixo foi enviado, junto com a imagem de cada página, ao Qwen2.5-VL 7B e ao Gemma 4 E4B, e também ao Gemini e ao Mistral OCR nos testes de configuração (Seção 5.2). Ele é definido na classe `VLMOCR` (`src/ocr/base_ocr.py`) do repositório do trabalho.

> *Transcreva fielmente todo o texto visível nesta página, preservando a ortografia, a acentuação e a pontuação originais, mesmo que arcaicas ou não padronizadas. Não modernize grafias históricas. Ignore elementos não textuais, como numeração de página, ornamentos tipográficos e marcas d'água. Responda apenas com o texto transcrito, sem comentários adicionais.*

O GLM-OCR e o DeepSeek-OCR foram treinados com instruções de tarefa fixas e receberam, respectivamente, apenas *Text Recognition:* e *Free OCR.* (27). Em todos os VLMs executados via Ollama, a janela de contexto foi de 6.144 *tokens* e o lote de processamento do *prompt*, de 128 *tokens*; os demais parâmetros de geração seguiram os valores padrão de cada modelo.

APÊNDICE C – CÓDIGO-FONTE

Todo o código-fonte deste trabalho, incluindo os adaptadores dos modelos, o benchmark, a análise dos resultados, o pipeline de extração e a regra ouro, está disponível em repositório público:

https://github.com/Ewaldouhlmann/tcc-ocr-bu-ufsc

O repositório está organizado como descrito no Tabela 13. As instruções de instalação e de execução estão no arquivo `README.md`, na raiz do repositório.

Tabela 13 – Organização do repositório do trabalho.

Caminho	**Conteúdo**
`src/ocr/base_ocr.py`	Classe abstrata `BaseOCR` e classes intermediárias `ClassicalOCR`, `TransformerOCR` e `VLMOCR`, com o *prompt* padronizado (Apêndice B)
`src/ocr/classical/`	Adaptadores do Tesseract, EasyOCR, PaddleOCR e DocTR
`src/ocr/transformer/`	Adaptadores das duas variantes do TrOCR
`src/ocr/vlm/`	Adaptadores dos VLMs executados via Ollama e dos serviços via API
`src/ocr/__init__.py`	Registro dos modelos (`MODEL_REGISTRY`)
`src/pipeline/extractor.py`	Pipeline de extração de obras completas (Apêndice A)
`benchmark/extrair.py`	Etapa de extração do benchmark, com medição de tempo e memória (Seção 5.4)
`benchmark/avaliar.py`	Etapa de avaliação: normalização, CER, WER e tabela de resultados (Seção 5.5)
`eda/analise_resultados.ipynb`	Figuras e tabelas do Capítulo 6, incluindo a análise de padrões de erro e de fidelidade ortográfica
`notebooks/`	Notebooks do Google Colab: execução dos VLMs em GPU e pipeline de extração
`data/corpus/regra_ouro/`	Transcrições de referência das 20 páginas e manifesto com obra, página e dificuldade (Capítulo 4)
`data/results/`	Saídas de cada modelo por página e métricas calculadas

Fonte: Elaborado pelo autor.